LEARN CILIUM

Livro do aluno: Cilium BGP, Gateway API e tenants híbridos

Guia de estudo e prática

Objetivo do módulo

Ao terminar este roteiro, a pessoa estudante consegue localizar os ambientes descritos para os exercícios dos módulos 1–11, explicar o que o Cilium anuncia por BGP, validar um Gateway HTTP/TCP/UDP exposto por VIP anycast, ler uma decisão de autorização na borda e no datapath, distinguir autorização por identidade de autorização por endereço em um tenant com pods Kubernetes e VMs OpenStack ou KubeVirt, e interpretar como leituras históricas o estudo em nuvem do módulo 12, os resultados comparados de P004 (MGC/OVN, OVN-Kubernetes `C/D`, Cilium OSS `A`, Cilium + FRR `B` e critérios de aceite para PoC do INV) do módulo 13 e os 16 estudos avançados de P005 (Ondas 1 a 4: conexão dedicada eBGP `E09–E19` e datapath eBPF, `netkit`, burst IPAM, XLB, DRA e Hubble `E21–E25`) do módulo 14.

Edição: 2.4 · Formato: módulos 1–11 com exercícios guiados apoiados nos ambientes P001–P003; módulo 12 de leitura histórica do estudo em nuvem, cuja infraestrutura fica fora da aula; módulo 13 de leitura dos resultados históricos completos de P004-S001 a P004-S008 (MGC, OVN-Kubernetes + KubeVirt, casos cruzados, Braços Cilium A e B + KubeVirt e síntese INV × equivalente aberto); módulo 14 de leitura dos resultados completos de P005-S001 a P005-S004 (16 estudos avançados de eBGP/Direct Connect `E09–E19` e Datapath eBPF/Escala/DRA/Hubble `E21–E25`)

Sumário

Capítulo	Página
Guia de estudo e prática	3
Como usar o guia	3
Mapa dos laboratórios	5
Vocabulário mínimo	7
A pergunta central: cada pod anuncia `/32`?	7
Módulo 1 — Baseline e o que o Cilium anuncia	7
Módulo 2 — VIP anycast e caminho do tráfego	8
Módulo 3 — Dual-stack IPv6 no plano de controle	9
Módulo 4 — Falhas, Graceful Restart e convergência	9
Módulo 5 — Escala e desempenho	10
Módulo 6 — Gateway API HTTP, TCP e UDP por VIP BGP	11
Módulo 7 — Autorização externa na borda	11
Módulo 8 — WireGuard em native routing e VXLAN	12
Módulo 9 — Tenants: rede, borda e configuração	13
Módulo 10 — Multi-Pool IPAM: /24 versus /32	13
Módulo 11 — Tenant híbrido: pods e VMs OpenStack	14
Módulo 12 — Nós reais na nuvem: o que muda	15
Módulo 13 — MGC, OVN, FRR e EVPN: o que os resultados provam	15
Módulo 14 — Estudos Avançados P005: Conexão Dedicada eBGP Datapath eBPF	20
15. Módulo 15 — Trilha P006: Datapath Avançado (`E26–E29`), Multi-Cluster & SRv6 (`E30–E33`) e Saneamento Integral (`C1–C4`)	23
Apêndice do instrutor	24
Limites do que foi demonstrado	25
Próximos estudos	25
Referências públicas	26

Guia de estudo e prática

Edição: 2.4 · Formato: módulos 1–11 com exercícios guiados apoiados nos ambientes P001–P003; módulo 12 de leitura histórica do estudo em nuvem, cuja infraestrutura fica fora da aula; módulo 13 de leitura dos resultados históricos completos de P004-S001 a P004-S008 (MGC, OVN-Kubernetes + KubeVirt, casos cruzados, Braços Cilium A e B + KubeVirt e síntese INV × equivalente aberto); módulo 14 de leitura dos resultados completos de P005-S001 a P005-S004 (16 estudos avançados de eBGP/Direct Connect `E09–E19` e Datapath eBPF/Escala/DRA/Hubble `E21–E25`) · Público-alvo: estudantes de Kubernetes, redes e Cilium que já conhecem o vocabulário básico de IP e roteamento

> Objetivo do módulo
>
> Ao terminar este roteiro, a pessoa estudante consegue localizar os ambientes descritos para os exercícios dos módulos 1–11, explicar o que o Cilium anuncia por BGP, validar um Gateway HTTP/TCP/UDP exposto por VIP anycast, ler uma decisão de autorização na borda e no datapath, distinguir autorização por identidade de autorização por endereço em um tenant com pods Kubernetes e VMs OpenStack ou KubeVirt, e interpretar como leituras históricas o estudo em nuvem do módulo 12, os resultados comparados de P004 (MGC/OVN, OVN-Kubernetes `C/D`, Cilium OSS `A`, Cilium + FRR `B` e critérios de aceite para PoC do INV) do módulo 13 e os 16 estudos avançados de P005 (Ondas 1 a 4: conexão dedicada eBGP `E09–E19` e datapath eBPF, `netkit`, burst IPAM, XLB, DRA e Hubble `E21–E25`) do módulo 14.

Esta edição preserva os módulos 1–11, com exercícios guiados e estudos das trilhas P001–P003 sobre BGP, Gateway API, segurança, IPAM e tenants híbridos. O módulo 12 é leitura do estudo histórico de nós reais na nuvem; essa infraestrutura não faz parte da aula. O módulo 13 apresenta a leitura completa dos resultados de `P004-S001` a `P004-S008` (concluídas com PASS): a réplica MGC com OVN, FRR e EVPN (`M01–M03` e `X05`), o plano OVN-Kubernetes + UDN/CUDN + EVPN + KubeVirt (`K01–K04`), os casos cruzados entre os três planos (`X01–X04`, `X06` e `X07`), o Braço Cilium A com KubeVirt `v1.9.0` no cluster `p003-gw` (`V00–V08-A`, `C-neg` / `G01` / `G02`), o Braço Cilium B com `FRR 10.7.1` no nó sob o invariante `R6=0` (`H6`/`G06`, `V09`/`H7`, `V07-B`, `V08-B`), o blueprint de transição para a Fase 2 (`Braços C e D`) e os critérios objetivos de aceite para uma PoC comercial do INV (`G07`) seguidos da higiene final dos laboratórios (`G08`). O módulo 14 sintetiza os 16 estudos avançados de `P005-S001` a `P005-S004` (todos concluídos com PASS): Braço A eBGP (`E09–E19`: idempotência `10x`, TCP MD5 + ASN 32 bits, `max-prefix` + filtro de import, communities/prepend/MED, BFD `< 1 s`, dual-border + Graceful Restart, eBGP IPv6 nativo `fd14::a/128`, VRF por tenant via community, 3 modos de retorno + `CiliumEgressGatewayPolicy`, e MTU 9000/QinQ/MACsec vs WireGuard) e Braço B Datapath eBPF (`E21–E25`: `netkit` vs `veth`, burst IPAM com warm pool, XLB L7 `sockmap`/`sk_msg` vs Envoy, DRA `resource.k8s.io/v1 NetworkDeviceData`, e observabilidade contínua BGP + Hubble L3/L4/L7/TLS). Os módulos 12, 13 e 14 interpretam evidência histórica; não exigem acesso em tempo real a essas infraestruturas. Nenhum módulo mede desempenho de hardware de produção.

Como usar o guia

Objetivos de aprendizagem

- explicar a diferença entre sessão BGP, rota anunciada e encaminhamento de um pacote;
- distinguir PodCIDR agregado, VIP de serviço e bloco Multi-Pool `/32`;
- expor um Gateway HTTP, TCP e UDP por uma VIP anunciada por BGP e provar cada listener com controle negativo;
- ler uma decisão allow/deny/absent do ExternalAuth e reconhecer fail-closed;
- verificar em captura se um tráfego está cifrado, encapsulado ou em claro;
- provar isolamento de tenant em três controles diferentes: rede, borda e configuração;
- explicar por que autorização por label não vaza no reuso de IP e por que autorização por CIDR vaza;
- registrar separadamente a saída observada e a expectativa do roteiro;
- interpretar os resultados de P004 (MGC/OVN/FRR/EVPN, OVN-Kubernetes + KubeVirt, casos cruzados e Braços Cilium A/B + KubeVirt, com todos os gates `G00–G09` concluídos), sem confundi-los com a trilha básica do Cilium.

Regras de segurança

- Os exercícios da pessoa estudante são de leitura e de requisição HTTP/TCP/UDP. Mutação é tarefa do instrutor e está marcada como tal.

- Não use `kubectl delete`, `kubectl drain`, `docker stop`, `clab destroy` ou o script de teardown como parte deste roteiro.
- Nunca dependa do contexto implícito do `kubectl`. Cada comando traz `--kubeconfig` e `--context`.
- O cluster `k01` é a referência histórica protegida. Os estudos P003 rodam em um segundo cluster, o sandbox `p003-gw`. Antes de qualquer comando no sandbox, confirme o UID do cluster com o valor entregue pelo instrutor.
- Se `127.0.0.1:18081` já responder no seu computador, existe um túnel ativo. Reutilize-o.
- O módulo 13 é somente leitura de evidências históricas: não traz comandos interativos para MGC, OVN-Kubernetes ou KubeVirt e não pede acesso à VM atual.

Onde um comando roda

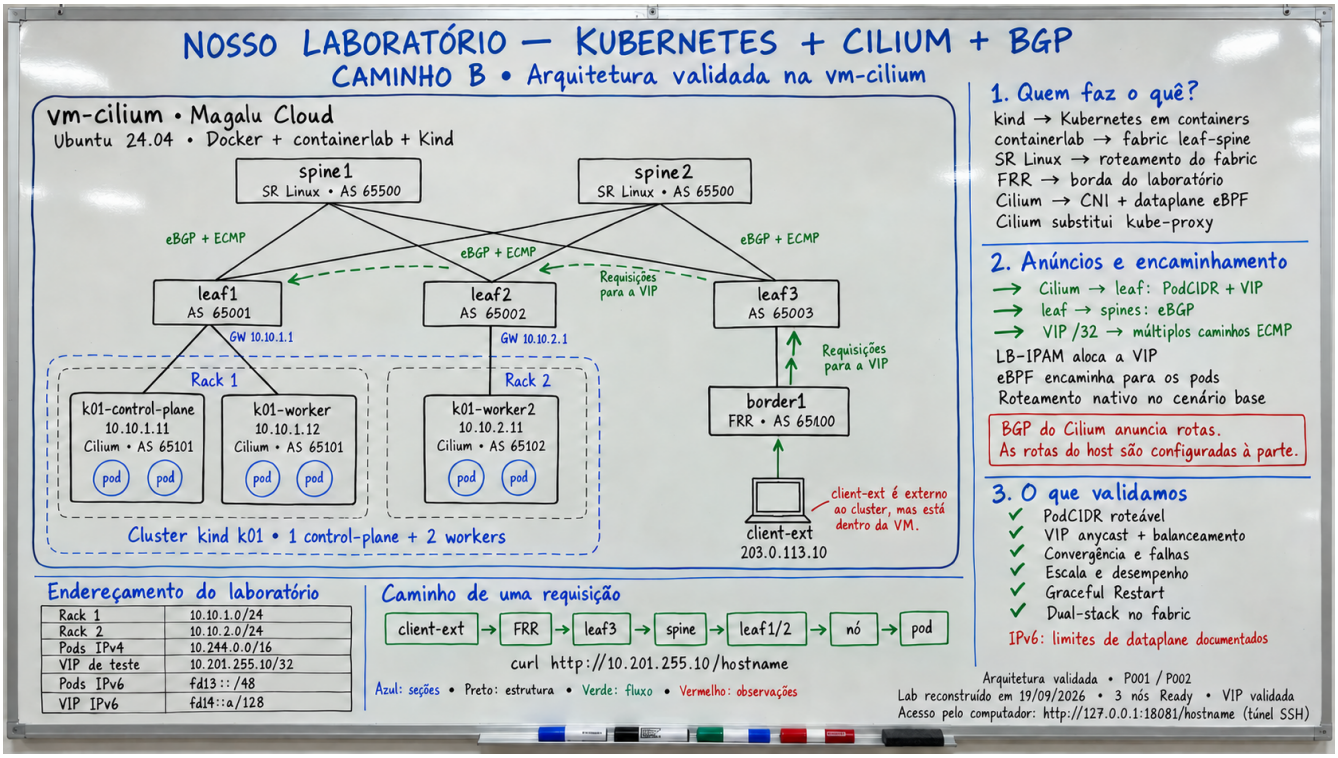
Rótulo	Significado
Mac	computador da pessoa estudante
vm-cilium	sessão SSH no host Linux do laboratório
container	comando precedido por `sudo docker exec` na vm-cilium
Kubernetes k01	`sudo kubectl --kubeconfig "$K01_KUBECONFIG" --context kind-k01`
Kubernetes sandbox	`sudo kubectl --kubeconfig "$STUDY_KUBECONFIG" --context kind-p003-gw`
testbed OpenStack	`sudo docker exec -i <container-do-testbed> bash` e, dentro dele, `openstack`

Defina as variáveis uma vez por sessão na vm-cilium. Os valores abaixo são os do laboratório de referência; use os que o instrutor entregar:

```
export LAB_DIR="${LAB_DIR:-/opt/poc-k8s-fabric}"
export K01_KUBECONFIG="${K01_KUBECONFIG:-/root/.kube/k01-rebuild.config}"
export STUDY_KUBECONFIG="${STUDY_KUBECONFIG:-/root/.kube/p003-gw.config}"
export STUDY_CLUSTER_UID="${STUDY_CLUSTER_UID:-<uid-entregue-pelo-instrutor>}"
k01() { sudo kubectl --kubeconfig "$K01_KUBECONFIG" --context kind-k01 "$@"; }
ks()  { sudo kubectl --kubeconfig "$STUDY_KUBECONFIG" --context kind-p003-gw "$@"; }
C1="sudo docker exec clab-poc-k8s-kind-client-ext"
C2="sudo docker exec clab-p003-gw-fabric-client"
UID_NOW="$(ks get namespace kube-system -o jsonpath='{.metadata.uid}')"
test "$UID_NOW" = "$STUDY_CLUSTER_UID" && echo "sandbox OK"
```

Se o teste de UID falhar, pare. Um `kubectl` no cluster errado invalida o exercício e pode alterar a referência.

Mapa dos laboratórios



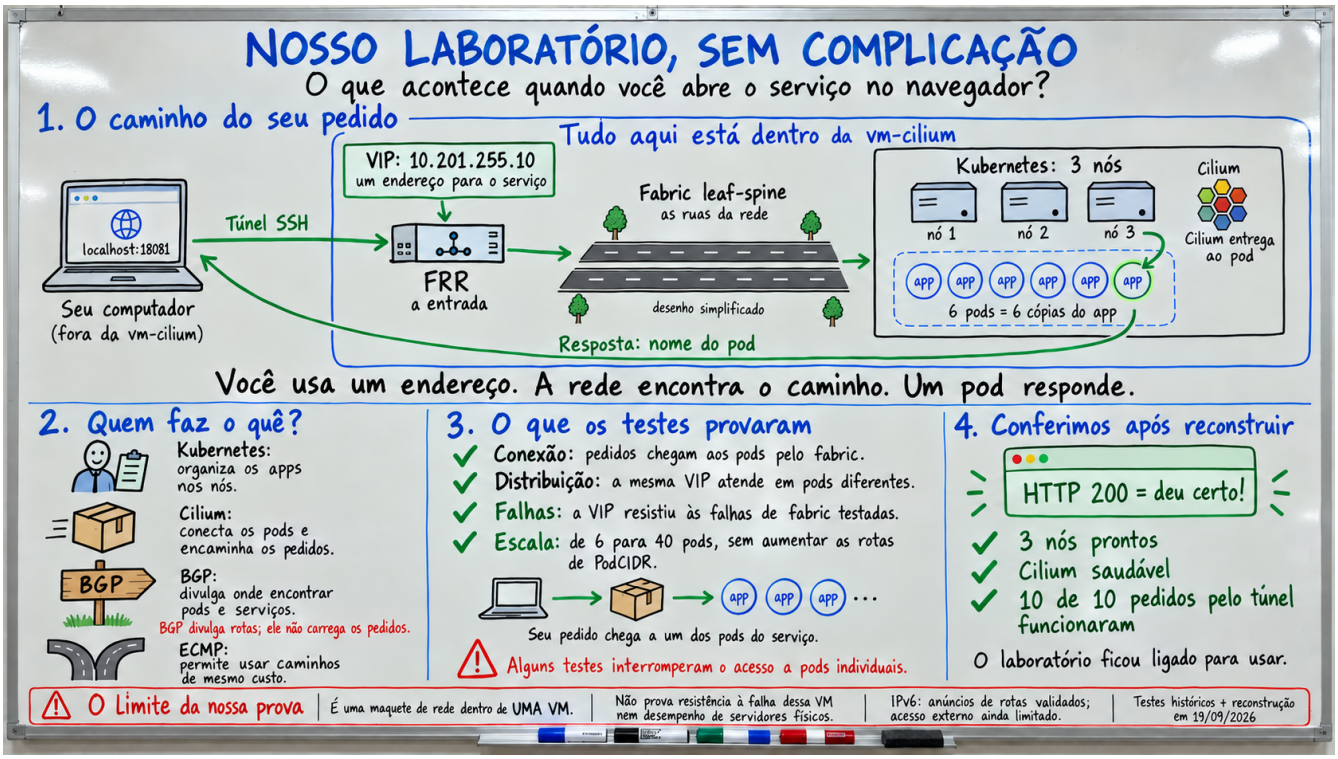
Os exercícios práticos dos módulos 1–11 usam os ambientes documentados nas linhas abaixo. O módulo 12 é leitura de um estudo com infraestrutura em nuvem que não faz parte da aula; o módulo 13 lê resultados históricos completos da trilha P004 (MGC, OVN-Kubernetes + EVPN, casos cruzados e Braços Cilium A/B + KubeVirt). A tabela distingue esses estudos dos ambientes usados nos exercícios:

Ambiente	Componentes	Versões	Papel
Lab de referência `k01`	2 spines + 3 leaves SR Linux, `border1` FRR, `client-ext`, kind com 3 nós	SR Linux `25.3.2`, FRR `8.4.1`, Kubernetes `v1.35.0`, Cilium `1.20.1`	Módulos 1 a 5; protegido, somente leitura
Sandbox `p003-gw`	segundo fabric containerlab + kind com 3 nós + cliente `198.19.0.10`	Cilium `1.20.2`, Gateway API `1.6.1` (CRDs standard + experimental)	Módulos 6 a 11; onde o instrutor muda configuração
Testbed OpenStack	DevStack em container (Neutron OVS, qrouter, qdhcp, SG)	neutron `34.x`, cirros `0.6.0`	Módulo 11; VMs do tenant
VM em KVM real	`qemu` no host ligado ao `br-int` do testbed por um par veth	cirros `0.6.0`	Módulo 11, caso C5
Estudo histórico de nós reais na nuvem	3 VMs na nuvem, cluster `kubeadm` e FRR na mesma VPC	Kubernetes `1.35.2`, Cilium `1.20.1`	Módulo 12; leitura, infraestrutura fora da aula
Réplica MGC (`P004-S002`)	`labctl mgc`: OVN `26.03.3`, 1 central, 2 chassis, 2 gateways, FRR multi-VRF e cliente AS 200	Linux VRFs nos gateways; EVPN Type 5 (`M01–M03`, `X05`)	Módulo 13.1; leitura de resultados históricos (`labctl mgc down` após os ensaios)
Plano OVN-Kubernetes + Fabric EVPN (`P004-S003` e `S004`)	`labctl evpn-fabric` + `labctl ovnk`: kind 3 nós + `ovnk-evpn-peer` + KubeVirt `/dev/kvm`	OVN-Kubernetes `v1.4.0`, KubeVirt `v1.9.0`, `frr-k8s` `v0.0.21`/`v0.0.27`	Módulo 13.2; leitura de resultados históricos (`K01–K04`, `X01–X04`, `X06–X07`)
Braços Cilium A e B + KubeVirt (`P004-S005` a `S008`)	`p003-gw` + KubeVirt `/dev/kvm` + `DaemonSet/frr-node` (no Braço B sob `R6=0`)	Cilium `1.20.2`, KubeVirt `v1.9.0`, FRR `10.7.1` (`table-map RM-NO-KERNEL`)	Módulos 13.3 e 13.4; leitura de resultados históricos (`V00–V09`, `G01`, `G02`, `G06–G08`)

A tabela descreve os ambientes e estudos documentados, sem indicar disponibilidade simultânea em tempo real (os perfis pesados operam em regime time-shared via `labctl` para respeitar `R3: MemAvailable >= 4,00 GiB`). Os quadros 05

e 06 ilustram os ambientes P001–P003; as figuras 07, 08 e 09 ilustram a arquitetura e os resultados de P004.

Os dois fabrics usam eBGP puro em dois níveis. No `k01`, os nós falam com o leaf do rack (AS 6510x para 6500x) e os leaves com os spines (AS 65500). No sandbox, os nós usam AS 65301/65302, os leaves 65201/65202/65203, os spines 65600 e o border 65400. Os enlaces spine–leaf são IPv4 numerados em `/31`.



Endereços que aparecem nos exercícios:

Recurso	Lab `k01`	Sandbox `p003-gw`
PodCIDR IPv4 por nó	`10.244.x.0/24`	`10.245.x.0/24` (IPAM `kubernetes`)
Pool de VIPs	`10.201.255.0/24`, VIP `10.201.255.10`	`10.202.255.0/24`, VIP `10.202.255.10`
Cliente externo ao cluster	`client-ext` `203.0.113.10`	`fabric-client` `198.19.0.10`
Gateway	não há	`p003-main` no namespace `p003-gateway`, listeners 8080/HTTP, 15432/TCP, 15353/UDP
Rede do tenant OpenStack	não há	`10.30.0.0/24` (subnet-a), externa `10.40.0.0/24`

Vocabulário mínimo

Termo	Significado neste laboratório
speaker	o agente Cilium em um nó, que mantém a sessão BGP daquele nó
PodCIDR	bloco de IP reservado para pods de um nó; `/24` IPv4 por nó no IPAM `kubernetes`
VIP	endereço de serviço anunciado como `/32` por vários nós
ECMP	vários próximos saltos equivalentes para o mesmo prefixo
GR	Graceful Restart: o vizinho mantém as rotas enquanto a sessão BGP reinicia
Gateway API	recursos `Gateway`, `HTTPRoute`, `TCPRoute`, `UDPRoute` implementados pelo Cilium com Envoy
ExternalAuth	filtro do Gateway API que consulta um serviço externo antes de encaminhar a requisição
CNP	`CiliumNetworkPolicy`; `fromEndpoints` seleciona por label, `fromCIDR` por endereço
Multi-Pool	IPAM do Cilium em que cada nó recebe blocos de um `CiliumPodIPPool`, com `maskSize` configurável
SG	Security Group do Neutron, o firewall stateful da porta de uma VM
RX morto	a VM envia mas não recebe; limitação de KVM aninhado em container

A pergunta central: cada pod anuncia `/32`?

Não com o IPAM padrão. Uma sessão BGP não é aberta por pod. O agente Cilium em cada nó é o speaker e anuncia o PodCIDR `/24` do nó. Um pod com `10.244.1.27` está coberto por `10.244.1.0/24`; não nasce sessão nem anúncio para `10.244.1.27/32`.

O serviço tem outra regra. O `echo-anycast` recebe a VIP `10.201.255.10`, usa `externalTrafficPolicy: Cluster` e os três nós anunciam a mesma `10.201.255.10/32`; o fabric instala vários próximos saltos e faz ECMP. A rota representa o serviço e seus pontos de entrada, não cada backend.

Existe uma terceira forma, medida no Módulo 10: com Multi-Pool IPAM e `maskSize: 32`, cada pod recebe um bloco `/32` próprio e o Cilium anuncia esse bloco. O speaker continua sendo o nó. O que muda é a granularidade, a quantidade de rotas e o momento em que um bloco é alocado e retirado.

Módulo 1 — Baseline e o que o Cilium anuncia

Ambiente: lab `k01`. Origem: P001 (REQ-001 a REQ-007).

1.1 Conferir os containers

Na vm-cilium:

```
sudo docker ps --format 'table {{.Names}}\t{{.Status}}' | grep -E 'clab-poc-k8s-kind|k01-'
$C1 ip -4 addr show dev eth1
```

Esperado: `spine1`, `spine2`, `leaf1`, `leaf2`, `leaf3`, `border1`, `client-ext` e três `k01-*`; o `client-ext` mostra `203.0.113.10` uma vez. Esse endereço pode sumir após um redeploy (lição L1 do RUNBOOK); sem ele todos os probes do módulo falham sem falha real.

1.2 Conferir o cluster e os PodCIDRs

```
k01 get nodes -o custom-columns=NODE:.metadata.name,PODCIDR:.spec.podCIDR,PODCIDRS:.spec.podCIDRs
k01 get pods -o wide
```

Responda no caderno: qual `/24` cobre o IP de cada pod `echo-*`? A resposta aponta para o bloco do nó, nunca para um `/32` do pod.

1.3 Sessões e anúncios BGP

```
sudo KUBECONFIG="$K01_KUBECONFIG" cilium --context kind-k01 bgp peers
sudo KUBECONFIG="$K01_KUBECONFIG" cilium --context kind-k01 bgp routes advertised ipv4 unicast
k01 get ciliumbgpclusterconfigs,ciliumbgppeerconfigs,ciliumbgpadvertisements
```

Esperado: três sessões `established` (uma por nó, nunca uma por pod), timers hold 9 s e keepalive 3 s, Graceful Restart habilitado com `restartTime` 30 s. Entre os anúncios aparecem o PodCIDR do nó e a VIP `10.201.255.10/32`.

O anúncio da VIP só existe porque o `CiliumBGPAdvertisement` tem um `selector` com `bgp-advertise=true` e o Service carrega esse label. Sem o selector o agente não anuncia nada de Service; este foi um achado repetido em nós reais.

1.4 A rota no spine e a ausência de encapsulamento

```
sudo docker exec clab-poc-k8s-kind-spine1 sr_cli \
  "show network-instance default route-table ipv4-unicast prefix 10.244.0.0/16 longer"
sudo docker exec clab-poc-k8s-kind-spine1 sr_cli \
  "show network-instance default route-table ipv4-unicast prefix 10.201.255.10/32 detail"
```

Esperado: os três `/24` e a VIP com dois próximos saltos. Em native routing o fabric vê o IP real do pod; a evidência histórica registra zero pacotes UDP/8472 no fio e um handshake `203.0.113.10 > 10.244.2.198:8080` direto ao pod.

Item	Esperado	Observado
Nós `Ready`	3	
Sessões BGP	3 established	
PodCIDRs no spine	3	
Next-hops da VIP no spine	2	

Módulo 2 — VIP anycast e caminho do tráfego

Ambiente: lab `k01`. Origem: P001 (REQ-008 a REQ-010).

2.1 Requisições a partir do client-ext

```
k01 get svc echo-anycast echo-local -o wide
for i in $(seq 1 20); do
  $C1 curl -fsS --max-time 5 http://10.201.255.10/hostname; echo
done | sort | uniq -c
```

Esperado: `echo-anycast` com `10.201.255.10` e `externalTrafficPolicy: Cluster`; `echo-local` com `10.201.255.11` e `Local`. Vinte amostras não garantem que todos os seis backends apareçam: ECMP e Maglev usam hashing. A execução de referência registrou 20/20 HTTP 200 e seis pods distintos.

ICMP para a VIP não é respondido: o balanceador BPF atende TCP; `ping` na VIP não é sinal de falha.

2.2 O túnel para o Mac

No Mac:

```
export VM_CILIUM_HOST="${VM_CILIUM_HOST:-IP_DA_VM}"
curl --silent --fail --max-time 2 http://127.0.0.1:18081/hostname || \
ssh -i ~/.ssh/id_rsa -o IdentityAgent=SSH_AUTH_SOCK -o ExitOnForwardFailure=yes -N \
  -L 127.0.0.1:18081:10.201.255.10:80 ubuntu@"${VM_CILIUM_HOST}"
```

O túnel termina no host da VM e encaminha uma porta local para a VIP. Ele não publica a VIP na Internet. A rota do host que permite ao próprio host alcançar a VIP é criada pelo instrutor com `scripts/06-expor-vip-na-vpc.sh`.

2.3 O caminho e o fix que o tornou possível

```
Mac → túnel SSH → vm-cilium → clab-ext → border1/FRR → leaf3
    → spine → leaf do rack → nó Kubernetes → Cilium bpf-lb → Service → pod
```

O balanceador BPF precisa estar anexado à interface do fabric (`eth1` no nó kind). O controlador de devices do Cilium 1.20.1 pula veths sem rota default, então o kit fixa `devices=eth+` nos values. Sem isso a VIP era roteada de volta ao fabric em loop. Um `helm upgrade` que regenere o ConfigMap remove a chave; o apêndice do instrutor mostra a verificação condicional.

Quando o cliente está fora da VM, na mesma VPC, o caminho é assimétrico: a requisição entra pelo fabric e a resposta volta pela bridge docker do host, porque o nó kind roteia a VPC por `eth0`. É uma propriedade da topologia, não uma falha.

Módulo 3 — Dual-stack IPv6 no plano de controle

Ambiente: lab `k01` reconstruído com `values-dualstack.yaml`. Origem: P002-S001.

3.1 Ler o que foi provado

```
k01 get nodes -o custom-columns=NODE:.metadata.name,PODCIDRS:.spec.podCIDRs
sudo KUBECONFIG="$K01_KUBECONFIG" cilium --context kind-k01 bgp routes advertised ipv6 unicast
sudo docker exec clab-poc-k8s-kind-spine1 sr_cli \
  "show network-instance default route-table ipv6-unicast prefix fd14::a/128 detail"
```

Esperado: cada nó com dois PodCIDRs (`10.244.x.0/24` e `fd13:0:0:x::/64`), os três `/64` no spine e a VIP `fd14::a/128` com dois próximos saltos. Uma única sessão BGP transporta as duas famílias; a convergência do plano de controle vale para ambas.

3.2 O que a topologia não entrega

A VIP IPv6 não é alcançável do `client-ext`: o underlay externo do lab é IPv4-only e next-hops IPv4-mapped não encaminham IPv6. O tráfego pod→pod IPv6 cross-node flui pela rede kind, não pelo fabric. São limites do lab em containers, não do Cilium nem do SR Linux. Não apresente alcance IPv6 fim a fim como demonstrado.

Quatro configurações são obrigatórias e ficaram no kit: `ipv6.enabled: true` nos values, `ipFamily: dual` com dois `podSubnet` no kind, `afi-safi ipv6-unicast` nos grupos `rack*-k8s` dos leaves e `multipath ipv6-unicast` nos spines.

Módulo 4 — Falhas, Graceful Restart e convergência

Ambiente: lab `k01`. Origem: P001 REQ-011, P002-S002 e P002-S004. Os gatilhos de falha são tarefa do instrutor; a pessoa estudante lê e interpreta.

4.1 Como se mede um blackhole

Três loops de `curl` com timeout de 2 s rodam no `client-ext` contra a VIP anycast, um pod do rack 1 (caminho único) e um pod do rack 2. Blackhole real é o maior intervalo sem nenhum OK; timeouts encadeados não contam (lição L4). Falhas de SR Linux são provocadas com `admin-state disable` via `sr_cli`, nunca com `docker stop`, que destrói a wiring veth (lição L2).

4.2 Resultados medidos

Falha	VIP anycast	PodCIDR do rack afetado	Reconvergência
Restart do agent, GR ON	0 falhas	sem blackhole	datapath BPF pinado sobrevive
Restart do agent, GR OFF	0 falhas (outros nós anunciam)	blackhole 10,6 s (P001) a 16,5 s (P002)	até o novo agent reanunciar
Drain do nó	blip de 50 a 300 ms no início da evicção	pods evictados	GR irrelevante: a sessão não cai
1 spine de 2	100% OK em 28,7 mil amostras	n/a	BGP re-up 33 a 38 s
1 leaf	100% OK (anycast segue pelo outro rack)	blackhole total do rack por 107 a 138 s	dados +44 a 48 s após enable
Spine 2 + leaf 1 juntos	100% OK em 34 mil amostras	blackhole total do rack 1	lab sobrevive degradado
Flap simultâneo de 2 workers, GR ON	0 de 19451 falhas	2,4% a 4,4% de falhas, maxgap 2 a 4 s, sem blackhole	agents ~52 s, estável ~82 s

Leituras que a pessoa estudante deve conseguir explicar:

- a VIP anycast `/32` com ECMP foi imune a todas as falhas de fabric testadas;
- o PodCIDR é caminho único por rack quando o nó é single-homed; a falha do leaf isola o rack;
- Graceful Restart elimina o blackhole de PodCIDR no restart do agent, em um nó ou em vários;
- dual-homing do nó daria ECMP ao PodCIDR; o simulador SR Linux não estabelece TCP/179 em porta adicionada em runtime, então isso fica para um cluster real.

4.3 O que a API do Cilium não expõe

`CiliumBGPPeerConfig` v2 na versão 1.20.x tem `timers`, `gracefulRestart`, `ebgpMultihop`, `families` e `authSecretRef`. Não há campo BFD. A detecção de falha de sessão hoje é hold 9 s e keepalive 3 s, o menor valor aceito na validação do lab. Essa lacuna é o ponto de partida de um dos próximos estudos.

Módulo 5 — Escala e desempenho

Ambiente: lab `k01`. Origem: P002-S003.

5.1 O que a pessoa estudante confere

```
sudo docker exec clab-poc-k8s-kind-spine1 sr_cli \
  "show network-instance default route-table ipv4-unicast summary"
k01 get deploy echo
```

Anote o total de rotas IPv4 no spine e o número de réplicas. O instrutor pode escalar o `echo` de 6 para 40 réplicas; repita o primeiro comando e compare.

5.2 Resultados medidos

Eixo	Resultado
Pods 6 → 40	13 s até Ready; RIB do fabric inalterado (26 = 26): o `/24` agrega
+10 VIPs `/32`	primeira no spine em 1,3 s; 10/10 em 4,2 s; ECMP de 2 next-hops por VIP
Burst de +30 VIPs	30/30 em 3,0 s; withdrawal completo em 6,0 s
Throughput pod→pod cross-node	27,5 Gb/s com 1 fluxo; 177 Gb/s com 8 fluxos; 193 Gb/s no sentido reverso
Latência pod→pod	0,094 ms ocioso; 0,039 ms sob 177 Gb/s, 0% perda
VIP sob carga	0 falhas em ~24,7 mil requisições
Overlay VXLAN versus native	MTU 1450 versus 1500; 11,2 versus 27,4 Gb/s com 1 fluxo

A propriedade de escala é a agregação: pods escalam sem tocar no BGP e a RIB cresce apenas com VIPs vezes nós, de forma linear. Os números absolutos vêm de SR Linux em container e veths do kind; use apenas as relações.

Módulo 6 — Gateway API HTTP, TCP e UDP por VIP BGP

Ambiente: sandbox `p003-gw`. Origem: P003-S003 e P003-S004.

6.1 O Gateway e seu Service

```
ks -n p003-gateway get gateway p003-main -o wide
ks -n p003-gateway get httproutes,tcproutes,udproutes
ks -n p003-gateway get svc -l bgp-advertise=true
sudo KUBECONFIG="$STUDY_KUBECONFIG" cilium --context kind-p003-gw \
  bgp routes advertised ipv4 unicast
```

Esperado: Gateway `Programmed=True` com `IPAddress 10.202.255.10`; o Service gerado pelo Cilium com `EXTERNAL-IP 10.202.255.10` e o label `bgp-advertise=true`, que vem de `spec.infrastructure.labels` do Gateway, não de `metadata.labels`. A VIP aparece nos anúncios BGP dos três nós.

6.2 Um listener por protocolo, com controle negativo

```
VIP=10.202.255.10
$C2 curl -sS --retry 0 --max-time 5 -H 'Host: echo.p003.study' \
  -w '\n%{http_code}\n' "http://$VIP:8080/hostname"
$C2 curl -sS --retry 0 --max-time 5 -H 'Host: wrong.example' \
  -o /dev/null -w '%{http_code}\n' "http://$VIP:8080/hostname"
$C2 sh -c "echo P003-nonce-1 | nc -w 3 $VIP 15432"
$C2 dig @"$VIP" -p 15353 study.p003 TXT +short +notcp +tries=1 +time=2
$C2 sh -c "echo P003-gw04 | nc -w 3 $VIP 15433"
```

Caso	Esperado	Observado
HTTP com Host correto	200 e hostname de um pod `http-echo-*`	
HTTP com Host errado	404 do Envoy	
TCP 15432	o nonce volta idêntico	
UDP 15353	`"P003-OK"`	
TCP 15433 sem listener	timeout, nenhuma chegada na fixture	

A matriz de referência registrou 30/30 em cada listener, 503 com EndpointSlice vazio quando o backend foi escalado a zero e recuperação completa ao restaurar. Quando o instrutor troca o `CiliumBGPAdvertisement` por um selector que não casa, a `/32` some do spine em cerca de 15 s, a VIP para de responder e o IP direto do pod continua funcionando: é o controle que separa "anúncio" de "serviço".

6.3 Achado: `hostNetwork` do Gateway não expõe listener no nó

`gatewayAPI.hostNetwork.enabled` no Cilium 1.20.2 é uma feature dos listeners Envoy (L7), controlada por `nodes.matchLabels`. Com o seletor vazio, nenhum socket abre no IP do nó nas portas 8080, 15432 ou 15353. Os probes ao nó nessas portas deram 180/180 falhas; os `nodePort` do Service gerado deram 180/180 sucessos. Para expor TCP/UDP no nó, o caminho suportado é o NodePort ou a VIP por BGP.

Módulo 7 — Autorização externa na borda

Ambiente: sandbox `p003-gw`. Origem: P003-S005, P003-S006 e P003-S009 (T05). O ExternalAuth do Gateway API é experimental na 1.20.2; o CRD `HTTPRoute` recebeu o schema experimental por um patch de spec, porque o `experimental-install.yaml` estoura o limite de annotations no Kubernetes 1.35.0.

7.1 A fixture

Um serviço Go em `studies/p003/fixtures/auth/` decide `allow`, `deny` ou `absent` a partir do header `X-Lab-Decision` e registra cada consulta com o `X-Lab-Request-ID`. Ele fala HTTP e gRPC (`envoy.service.auth.v3`). Não é um IdP; serve para observar a decisão, não para autenticar pessoas.

7.2 Três decisões, dois protocolos

```
for d in allow deny ""; do
  $C2 curl -sS --retry 0 --max-time 15 -H 'Host: echo.p003.study' \
    ${d:+-H "X-Lab-Decision: $d"} -H "X-Lab-Request-ID: aluno-$RANDOM" \
    -o /dev/null -w "decisao=${d:-absent} http=%{http_code}\n" \
    "http://10.202.255.10:8080/protected-http"
done
$C2 curl -sS --retry 0 -o /dev/null -w 'public http=%{http_code}\n' \
  -H 'Host: echo.p003.study' http://10.202.255.10:8080/public
```

Decisão	HTTP	gRPC
allow	200	200
deny	403	403
absent	401	401
rota pública sem auth	200	200

A matriz A01–A10 executou 900 requisições com esse resultado. O header forjado `X-Lab-User` enviado pelo cliente não aparece na resposta (A08). A rota pública não consulta o autorizador (A09).

7.3 Fail-closed sob degradação

Cenário	HTTP	gRPC	Conclusão
autorizador escalado a zero	403 em 2 ms	403	fail-closed
autorizador com atraso de 15 s	403 após 10 s	403 após ~200 ms	timeout do Envoy difere por protocolo
`backendRef` inexistente	500	500	`ResolvedRefs=False`
porta errada	403	403	`BackendNotFound`
cross-namespace sem `ReferenceGrant`	500	500	`RefNotPermitted`
`ReferenceGrant` removido durante probes	403 → 500 em até 2 s	200 → 500 em até 2 s	revogação sem bypass

Nenhum cenário liberou a aplicação. Dois defeitos ficaram registrados na 1.20.2: com Grant válido, a rota HTTP cross-namespace com decisão allow pendura (gRPC funciona), e um bloco `http: {}` vazio devolve 401 para todas as decisões. `allowedResponseHeaders` não encaminhou os headers do autorizador ao cliente.

Módulo 8 — WireGuard em native routing e VXLAN

Ambiente: sandbox `p003-gw`. Origem: P003-S007 e P003-S008. Os perfis são trocados pelo instrutor com `helm upgrade`; a pessoa estudante confere interfaces e capturas.

8.1 Três perfis

Perfil	Configuração	Sinal na bridge do underlay
W0	criptografia desligada	native: payload em claro; VXLAN: UDP/8472 com payload em claro
W1	`encryption.type=wireguard`	UDP/51871 para o tráfego pod→pod remoto
W2	W1 + `nodeEncryption.enabled=true`	UDP/51871 também para tráfego de nó

```
ks -n kube-system exec ds/cilium -- cilium-dbg encrypt status
ks -n kube-system exec ds/cilium -- ip -br link show cilium_wg0
```

8.2 O que as 24 células mostraram

Quatro placements (auth e app no nó A ou no nó B, ingress fixo no nó A) vezes três perfis vezes duas topologias (native e VXLAN): 90 allow com 200 e 90 deny com 403 em cada célula, zero drops no `cilium-dbg monitor`. O handshake Envoy→autorizador relatado na issue 46768 não se reproduziu na 1.20.2 em nenhuma combinação.

O achado de segurança é outro: em native routing, a perna Envoy→pod de auth por IP direto atravessa em claro no underlay mesmo com WireGuard de pod ativo (20 IDs de requisição legíveis por célula com auth remoto). Em VXLAN a mesma perna sai cifrada em W1 e W2. A exposição depende da topologia, não da decisão de auth. Ao desenhar criptografia, trate o tráfego originado pelo Envoy do nó como tráfego de nó.

Módulo 9 — Tenants: rede, borda e configuração

Ambiente: sandbox `p003-gw`. Origem: P003-S009, matriz T01–T17.

9.1 Três controles diferentes

Controle	Mecanismo	O que impede
Rede	`CiliumNetworkPolicy` por identidade e porta	A alcançar B e vice-versa em conexões novas
Borda	ExternalAuth no listener HTTP	usuário sem credencial na rota protegida
Configuração	RBAC + `allowedRoutes` + `allowedListeners` + `ReferenceGrant` + PSA `restricted`	tenant editar policy alheia, criar Gateway de contorno, subir pod privilegiado

9.2 Ler um drop de policy

```
ks get ciliumnetworkpolicies -A
ks -n kube-system exec ds/cilium -- \
  cilium-dbg monitor -t drop --related-to 0 2>/dev/null | head -20
```

Com o instrutor gerando tráfego A→B, você deve ver drops com `Policy denied` e o log da aplicação de destino vazio: o pacote não chega. Isso é diferente de um 403 na borda, que é gerado pelo Envoy antes da aplicação.

9.3 Resultados

Todos os 17 casos passaram. Os negativos foram reais: chamadas de API impersonadas devolveram `Forbidden` (não apenas `can-i`), o PSA `restricted:v1.35` rejeitou `hostNetwork`, `privileged`, `hostPID` e `hostPath`, e labels de tenant ausentes ou forjados não executaram. A TLS do backend (`BackendTLSPolicy`) falhou antes do request HTTP com CA errada, SAN errado ou certificado expirado.

Um detalhe que muda desenho: o ExternalAuth protege apenas o listener HTTP. O listener TCP sob a mesma VIP respondeu 200 para o tenant errado até uma CNP L4 ser aplicada (T07). Autorização L7 não é política L4.

Módulo 10 — Multi-Pool IPAM: /24 versus /32

Ambiente: sandbox `p003-gw`, com IPAM trocado para `multi-pool` pelo instrutor e restaurado ao final. Origem: P003-S010, matriz I01–I10.

10.1 Dois braços com a mesma variável

Braço	Pool	`maskSize`	`preAllocate`	Anúncio
M24	`10.250.0.0/16`	24	8	`CiliumPodIPPool` com community `65301:100`
M32	`10.252.0.0/16`	32	8	idem

```
ks get ciliumpodippools -o wide
ks get ciliumnodes -o custom-columns=NODE:.metadata.name,POOLS:.spec.ipam.pools.allocated
sudo docker exec clab-p003-gw-fabric-border1 vtysh -c 'show ip bgp' | grep -E '10\.25[02]\.'
```

10.2 O que muda entre `/24` e `/32`

Pergunta	M24	M32
Pod novo	cai num `/24` já alocado; zero eventos de bloco	cada pod ganha um `/32`; alocado e anunciado em 1 a 2 s
40 pods	3 rotas no border	40 rotas no border, uma por pod
Pod `NotReady` sem delete	bloco e rota permanecem; IP direto responde 200; o Service exclui o pod	idêntico
Apagar 1 pod	bloco retido: `roundUp(inUse+8, 8)` não encolhe	idêntico; o piso de `preAllocate` domina
Voltar a zero pods	blocos `/24` retidos por mais de 120 s	encolhe em 42 s no operador e 48 s na RIB, até o piso de 8 `/32` por nó
Recriar pod no mesmo nó	IP novo dentro do mesmo `/24`	alterna entre `/32` recém-liberados; sem IP estável
Peer BGP do border desligado	prefixos somem em ~10 s; pod e VIP dão 000	idêntico

Duas lições. O datapath não gateia readiness: rota e alcance direto ao pod existem enquanto o IP existir, e só o Service respeita `Ready`. A retirada de um bloco depende de `preAllocate`, não da morte do pod; um `/32` não é "retirado quando o pod morre".

Módulo 11 — Tenant híbrido: pods e VMs OpenStack

Ambiente: sandbox `p003-gw` + testbed OpenStack + VM em KVM real. Origem: P003-S011 a S016. As sínteses públicas completas estão em E08 e C5.

11.1 A pergunta

Um IP pode mudar de dono. Se a autorização for por endereço, o novo dono herda a concessão. A matriz C01–C09 responde: a autorização segue a identidade ou o endereço?

11.2 O caminho VM → pod

```
VM (tap) → OVS br-int (VLAN 1) → qrouter netns → br-ex → veth para o host
  → FORWARD do host → fabric do sandbox → nó worker → CNP ingress → pod
```

Há dois pontos de decisão: o Security Group na porta da VM (plano de controle do Neutron) e a CNP no pod (drop antes do pod; os contadores do pod ficam flat). Para provar que o deny foi na policy e não na rede, use `cilium-dbg monitor` no worker do pod e os contadores `/proc/net/snmp` dentro do pod.

11.3 O contraste que importa

	C03: pods, `fromEndpoints`	C05: VM, `fromCIDR`
Âncora da autorização	label do endpoint (identidade)	IP da origem (endereço)
IP reaproveitado por outro dono	negado, 100% de perda	permitido, o novo dono herda
Reautorizar após IP novo (C04)	n/a	efetivo em 4 a 9 s
Revogar (C05)	n/a	efetivo em 1 a 7 s
Conclusão	seguro	seguro só sob sequenciamento manual

Sequenciamento manual testado: revogar o CIDR, confirmar o bloqueio por conexões novas, só então reutilizar o IP e reautorizar o novo dono. Nenhum controlador sincroniza identidade Kubernetes com Security Group Neutron nesta trilha.

Três armadilhas do Cilium 1.20.2 nesse desenho: `egress: []` não é default deny (use `egressDeny`), `ingress: []` é inválido (revogue apontando o `fromCIDR` para um IP que a VM não tem) e uma `HTTPRoute` ampla com `path: /` faz fallback quando a rota específica é removida, tornando a revogação por rota ineficaz.

11.4 Caso C5: a VM precisa de KVM real

Com a VM dentro do container do testbed (KVM aninhado), a TX funciona e a RX morre: o sentido pod→VM dava timeout. Movendo a VM para `qemu -enable-kvm` no host e ligando sua NIC ao `br-int` do container por um par veth com `tag=1`, os dois sentidos deram 0% de perda, o IP veio do `qdhcp`, o egress passou pelo `qrouter` e o SG ficou ativo. A CNP no pod de teste permitiu com `fromCIDR` igual ao IP da VM e negou com 100% de perda ao retirá-la.

A pessoa estudante confere, com o instrutor:

```
ks -n p003-test get pods -o wide
ks -n p003-test exec echo-0 -- ping -c 3 -W 2 10.30.0.50
ks -n p003-test get cnp -o yaml | grep -A3 fromCIDR
```

Se a VM cair em `169.254.x.x`, a causa está em uma de duas coisas: falta a tag VLAN no veth do container, ou o dnsmasq do `qdhcp` não recarregou o `dhcp-hostsfile` (`kill -HUP`). Capture o DHCP nas duas pontas para isolar.

Módulo 12 — Nós reais na nuvem: o que muda

Origem: P002-S005 e P002-S006. Este módulo é leitura; a infraestrutura de nuvem não faz parte da aula.

Em três VMs reais da nuvem, `kubeadm` 1.35.2 sem kube-proxy e Cilium 1.20.1 funcionaram 1:1 com overlay VXLAN (MTU 1450, RTT ~0,9 ms). Um FRR externo na mesma VPC recebeu por eBGP os três PodCIDR `/24` e a VIP anycast `/32` com ECMP de três next-hops: o cenário do lab reproduziu-se em fabric real.

O que a plataforma bloqueou é a lição: com o guard de spoofing de IP da porta ligado, SYNs com origem de pod saíam da NIC e não voltavam, e pacotes com destino que não é o IP da porta (VIP anycast, IP de pod) eram descartados antes do nó. A prova causal foi um toggle ON→OFF→ON na porta de um único nó: com OFF, pod direto, VIP por BGP, VIP por rota estática e conexão nova pod→FRR sem SNAT funcionaram; com ON, apenas NodePort. A API reportou `false` antes de o datapath aceitar; um canário FRR→pod é o único readiness confiável.

Para native routing ou VIP anycast em nós reais, a porta precisa aceitar origens e destinos além do seu próprio IP, por allowed-address-pairs ou guard desligado. Isso é uma decisão de postura de segurança da VPC, não um ajuste do Cilium.

Módulo 13 — MGC, OVN, FRR e EVPN: o que os resultados provam

Este módulo é uma leitura guiada dos resultados históricos completos de `P004-S001` a `P004-S008` (concluídas com PASS). Os perfis `labctl/labs/{mgc,evpn-fabric,ovnk,p003-gw}.sh` e os artefatos de `studies/p004/{ovn,evpn-fabric,ovnk,cases,cilium-a,cilium-b}/` estão no repositório como referência de instrutor, mas a atividade deste módulo é interpretar as medições comparadas sem depender do estado atual da VM.

13.1 Plano MGC Connect (`P004-S002`: OVN + FRR multi-VRF e `X05`)

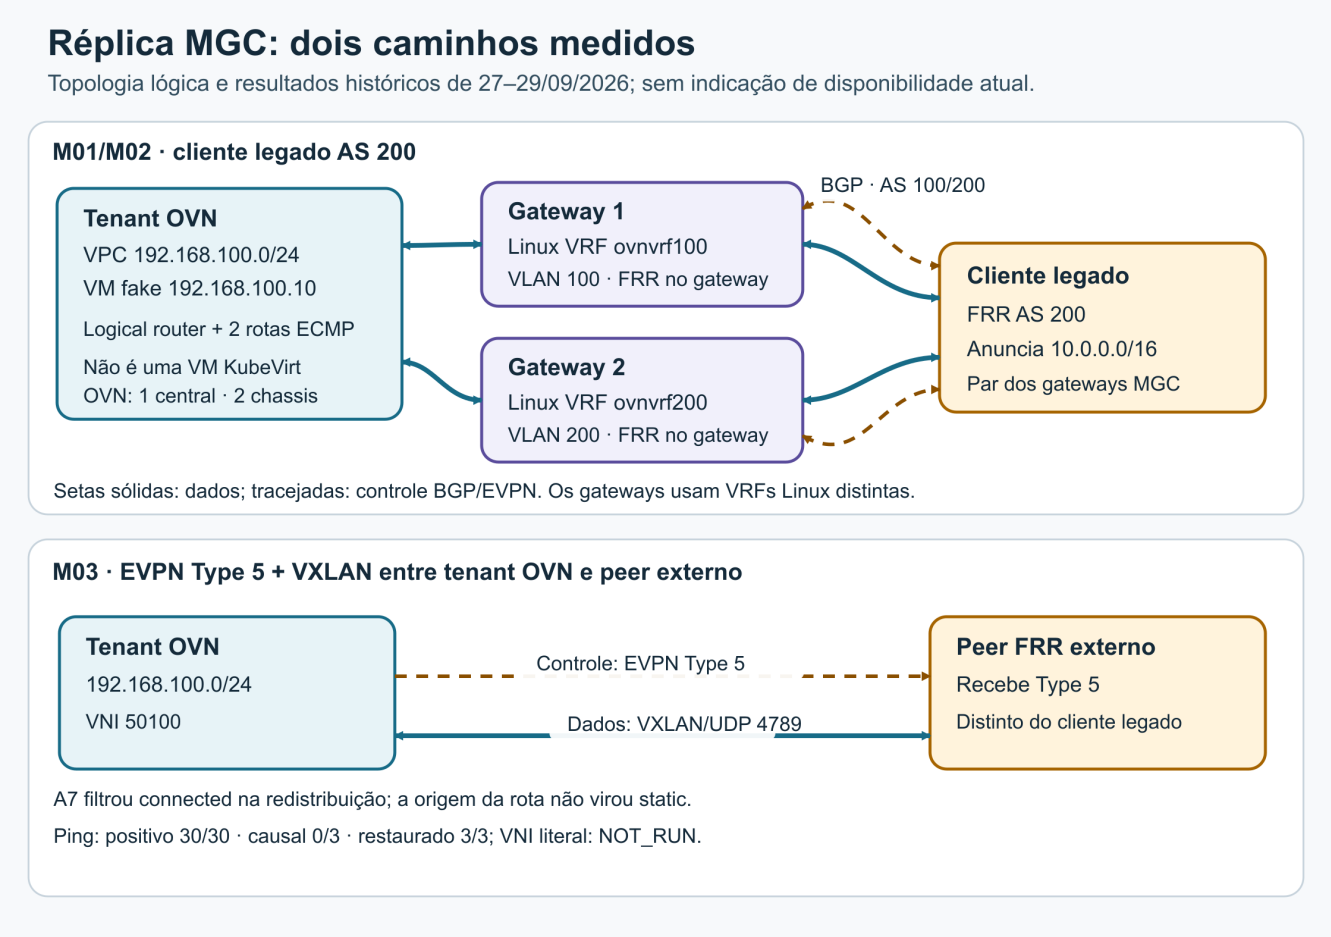


Figura 07 — Topologia lógica dos caminhos medidos na réplica MGC; o desenho não representa um inventário ou estado operacional atual.

O tenant OVN usou a rede `192.168.100.0/24`, com uma VM fake em `192.168.100.10`. Dois Connect Gateways tinham as Linux VRFs `ovnvrf100` e `ovnvrf200`, com FRR dentro dos próprios gateways. Cada gateway mantinha uma sessão BGP com o cliente legado AS 200, que anunciava `10.0.0.0/16`. Esse caminho sustenta a leitura de M01 e M02. O peer externo usado em M03 e X05 é outro caminho: ele recebeu as rotas EVPN Type 5 dos tenants, identificadas pelo VNI `50100` (tenant A) e pelo VNI `50200` (tenant B em X05); não era o cliente legado nas VLANs 100 e 200.

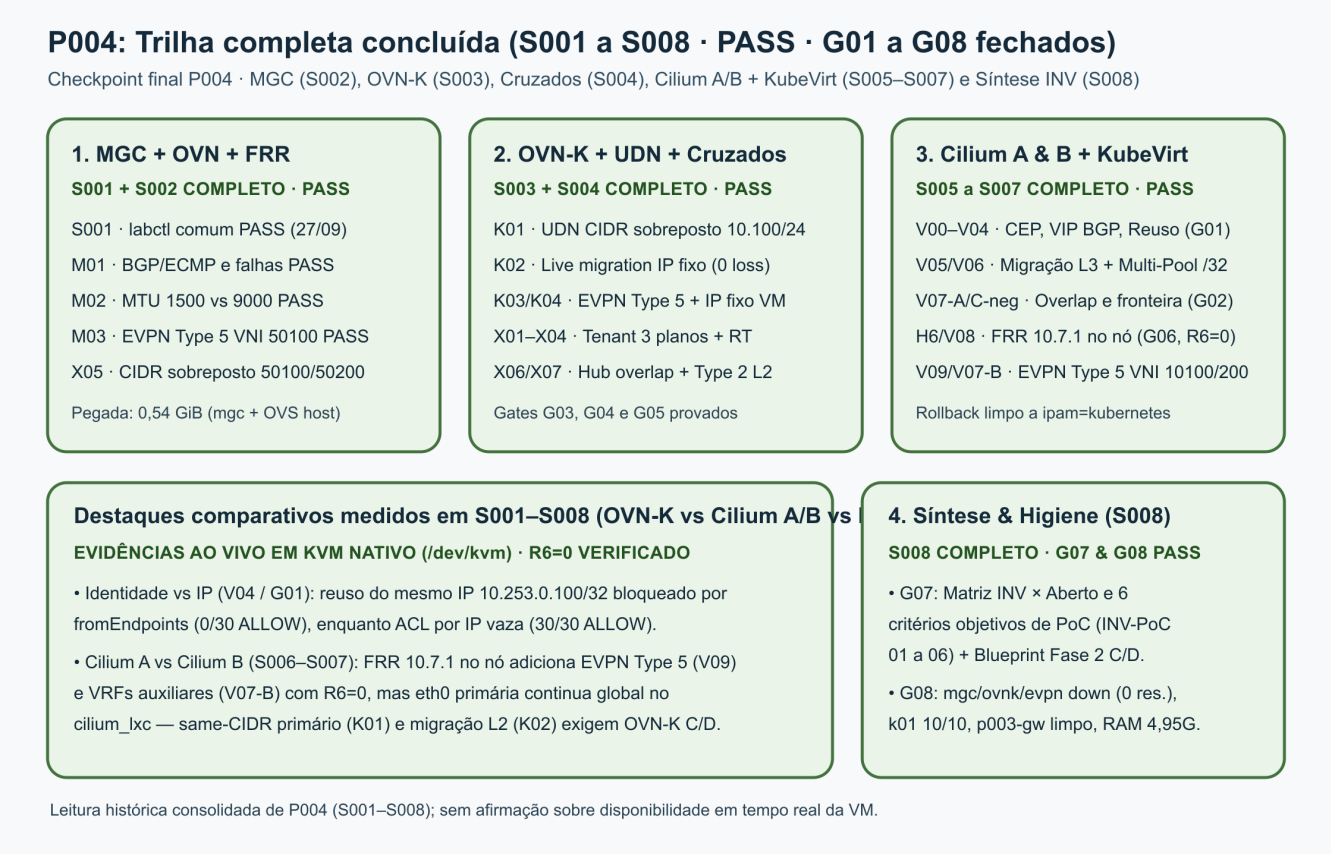


Figura 08 — Trilha P004 concluída com PASS de S001 a S008 (`G01` a `G08` fechados).

M01 passou com uma exceção de escopo: o fault de FRR parou `bgpd`, `bfdd` e `zebra` dentro de `ovn-gw-1`, não um container FRR separado. Os gateways usaram FRR 10.7.0 e o cliente, 8.4.1_git. Withdraw e faults controlados preservaram o tráfego medido, mas a falha do chassis `ovn-chassis-1` não foi testada; esse host hospedava a fixture da VM fake e era distinto do plano central OVN.

M02 passou sob o escopo aceito: com MTU 1500, pacotes pequenos passaram 30/30, mas o pacote IPv4 jumbo de 9000 B com DF não recebeu resposta em 30 tentativas (0/30) e o roteador devolveu ICMP Frag Needed com MTU 1500. Com MTU 9000, os pacotes pequenos e jumbo passaram 30/30; depois, as MTUs foram restauradas a

1. A reprodução literal do fragmento no tap físico da PoC permaneceu parcial.

M03 passou com um controle negativo causal. O positivo alcançou `192.168.100.0/24` como Type 5 no VNI `50100` e o ping respondeu 30/30. No controle causal, A7 definiu `dynamic-routing-redistribute=static` na LRP tenant. Esse filtro excluiu rotas `connected` dos anúncios; não converteu a origem da rota para `static`. A seleção retirou a rota-alvo do SB, a rota tenant, o Type 5 e a FIB, e o ping teve 0/3 respostas. BGP, VTEP e duas rotas colaterais permaneceram. Ao restaurar a chave ao estado ausente, o caminho voltou e o ping respondeu 3/3. O controle negativo literal do VNI ficou NOT_RUN: não havia causalidade estabelecida com o withdraw da rota exportada pelo router/FRR.

X05 fechou com PASS em 23/10/2026 (`run c9d0e1 G0→G8 RC=0` e prova negativa de rollback `b8c9d0 G7+G8 PASS`). Um segundo tenant B foi criado com a mesma sub-rede `192.168.100.0/24` (host `192.168.100.10`) e o mesmo `/30` de trânsito `169.254.254.0/30`, isolado no VRF `ovnvrf50200` (VNI `50200`, RT `65000:50200`). O alcance intra-tenant passou 30/30 nos dois tenants (`10.250.0.1 -> 192.168.100.10` no VNI `50100` e `10.251.0.1 -> 192.168.100.10` no VNI `50200`), enquanto as quatro direções cross-tenant tiveram `0/3` respostas e `0` pacotes capturados no `tcpdump` da interface de destino. Para que o Linux VXLAN bridge do peer desencapsulasse a rota EVPN Type 5 para o roteamento L3 do VRF, o `Router MAC` anunciado pelo gateway precisou coincidir com o MAC de `br-vxlan50200` (`02:00:00:20:00:01`). O rollback canônico retirou primeiro os anúncios BGP/EVPN antes de remover os objetos OVN NB e os VRFs, encerrando com `0` resíduos.

13.2 OVN-Kubernetes + UDN/EVPN + KubeVirt e Casos Cruzados (`P004-S003` e `P004-S004`)

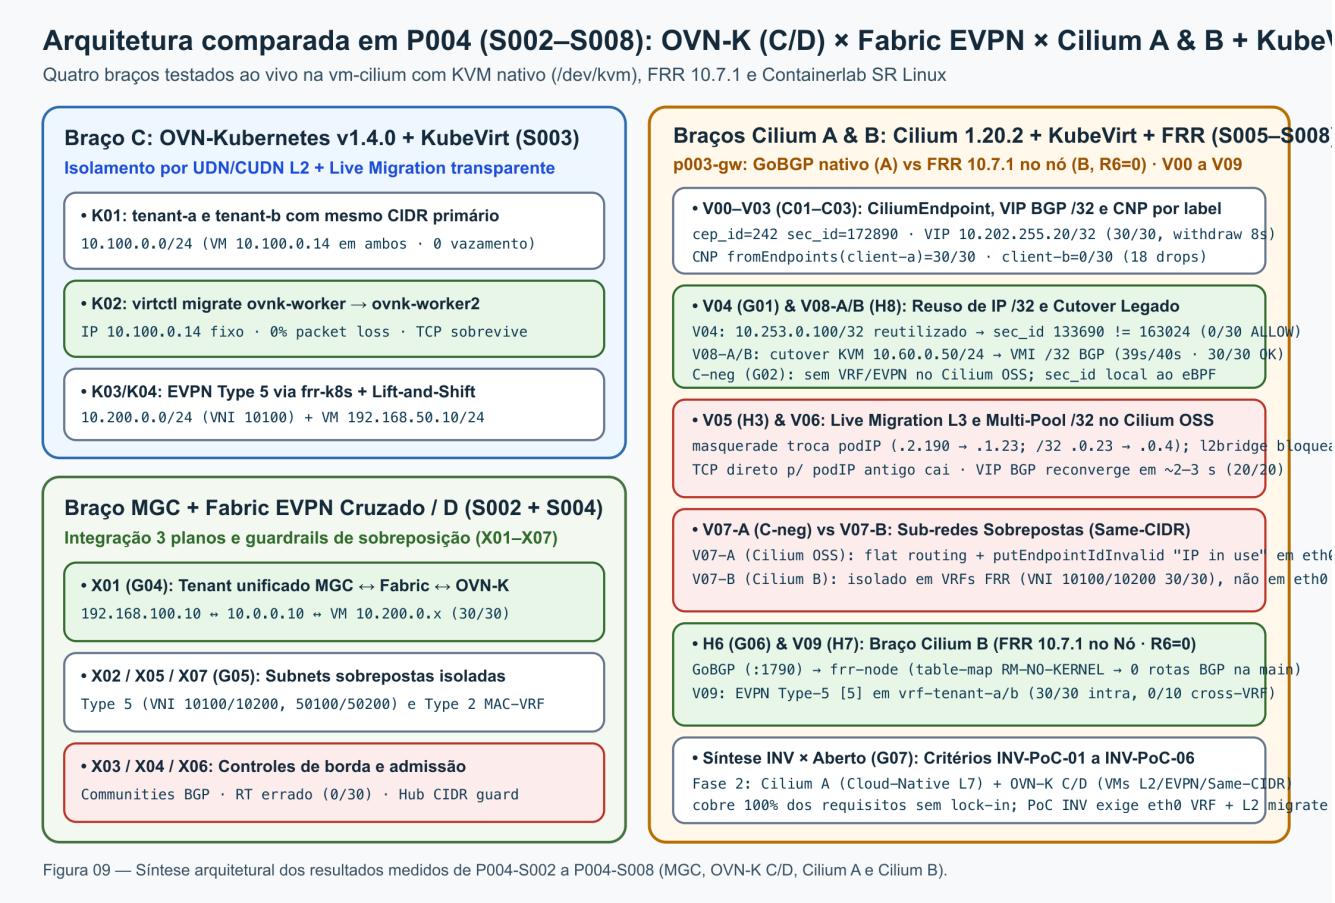


Figura 09 — Síntese arquitetural dos resultados medidos de P004-S002 a P004-S008 (MGC, OVN-K C/D, Cilium A e Cilium B).

Figura 09 — Comparação experimental entre os braços testados em P004-S002 a P004-S008 com KVM nativo (`/dev/kvm`), EVPN, Cilium 1.20.2 e FRR 10.7.1 (`R6=0`).

Na sessão `P004-S003` (PASS em 23/10/2026), os perfis `labctl evpn-fabric` e `labctl ovnk` subiram um cluster Kind de 3 nós com OVN-Kubernetes `v1.4.0`, KubeVirt `v1.9.0` em KVM nativo (`/dev/kvm`) e `frr-k8s` `v0.0.27`, provando o gate `G03` (`K01–K04`):

- K01 (UDN com CIDR sobreposto): duas `UserDefinedNetwork` primárias (`tenant-a` e `tenant-b`) usaram o mesmo CIDR `10.100.0.0/24`; as VMs `vm-a` e `vm-b` receberam o mesmo IP `10.100.0.14`, responderam `30/30` dentro do próprio tenant e tiveram `0/30` entre tenants.
- K02 (Live Migration com IP e sessão preservados): `virtctl migrate vm-a` moveu a VM entre `ovnk-worker` e `ovnk-worker2` em `~16 s`, preservando o IP `10.100.0.14/24` na UDN Layer2 com `0%` de perda de pacotes ICMP (`60/60`) e sobrevivência da sessão TCP longa.
- K03 e K04 (EVPN Type 5 e Lift-and-Shift): `ClusterUserDefinedNetwork` (`10.200.0.0/24`) anunciada via `RouteAdvertisements` + `frr-k8s` ao `evpn-fabric` (VNI `10100`, `30/30` positivo, `0/10` negativo) e preservação de IP fixo legado (`192.168.50.10/24` em `K04`).

Na sessão `P004-S004` (PASS em 24/10/2026), os casos cruzados `X01–X04`, `X06` e `X07` integraram simultaneamente os planos `mgc`, `evpn-fabric` e `ovnk` + KubeVirt, provando os gates `G04` e `G05`: conectividade fim a fim do tenant unificado (`X01`, `30/30`), isolamento em 3 planos com `10.200.0.0/24` e `10.0.0.0/24` sobrepostos (`X02`, `0` pacotes vazados), filtragem por BGP community (`X03`), bloqueio de Route-Target incorreto (`X04`, `0/30`), detecção de colisão de CIDR em VRF hub (`X06`) e extensão L2 em `MAC-VRF` EVPN Type 2 com mesmo CIDR `172.16.50.0/24` (`X07`, VNIs `20100` vs `20200`).

13.3 Braço Cilium A: `Cilium 1.20.2` + `KubeVirt v1.9.0` no `p003-gw` (`P004-S005`)

Na sessão `P004-S005` (PASS em 24/10/2026), o KubeVirt `v1.9.0` foi instalado no cluster sandbox `p003-gw` (`Cilium 1.20.2`) após descer `ovnk`/`evpn-fabric`/`mgc` via `labctl down` (cumprindo `MemAvailable >= 4 GiB`), e os casos `V00–V06` (`C01–C06`) foram medidos ao vivo:

- V00 e V01 (C01 — Datapath KVM e CiliumEndpoint): a VM CirrOS vm-a (binding: masquerade sobre /dev/kvm) comunicou-se bidirecionalmente com pods (30/30 nos dois sentidos; 0/30 com runStrategy=Halted). No Cilium, o pod virt-launcher apareceu como CiliumEndpoint (cep_id=242, sec_identity=172890, ip=10.245.2.231 no PodCIDR 10.245.2.0/24), enquanto o guest interno operou com eth0 = 10.0.2.2/24.
- V02 e V03 (C02/C03 — VIP BGP /32 e CiliumNetworkPolicy): o Service LoadBalancer vm-a-vip (10.202.255.20/32, bgp-advertise=true) foi anunciado em border1 (30/30 HTTP 200 de 198.19.0.10, withdraw em 8 s -> 0/30). A CiliumNetworkPolicy por label (fromEndpoints: app=p004-client-a) permitiu 30/30 de client-a e bloqueou 0/30 de client-b com 18 drops Policy denied no cilium-dbg monitor.
- V04 (C04 / Gate G01 — Reuso determinístico de IP /32 vs Identidade Cilium): usando o pool p004-single-ip (10.253.0.100/32), vm-a-reuse (sec_id=163024, ip=10.253.0.100) obteve 30/30 ALLOW em target-srv:8080. Após sua deleção, vm-b-reuse herdou o mesmo IP 10.253.0.100, mas recebeu sec_id=133690 != 163024 e obteve 0/30 ALLOW sob fromEndpoints(app=p004-vm-a) (25 drops Policy denied), enquanto uma ACL ancorada exclusivamente em IP (-s 10.253.0.100/32) concedeu 30/30 ALLOW ao IP reutilizado.
- V05 (C05 / H3 — Live Migration no Cilium OSS): a migração de p003-gw-worker (10.245.2.190) para p003-gw-worker2 (10.245.1.23) em 22 s trocou o IP do virt-launcher e derrubou a sessão TCP aberta para o podIP antigo (tcp_long_survived=no), enquanto a VIP BGP 10.202.255.20/32 reconvergiu automaticamente (max_gap_ms=3000.0ms).
- V06 (C06 / H4 — Multi-Pool /32 BGP + Migração + Rollback): em ipam.mode=multi-pool (p004-vm, maskSize: 32), vm-a recebeu 10.252.0.23/32 (30/30 probes diretos de 198.19.0.10 via border1); após migrar para worker2, recebeu 10.252.0.4/32 (30/30 probes diretos, enquanto 10.252.0.23/32 ficou retido no CiliumNode de origem pelo piso multiPoolPreAllocation). Ao final, o rollback restaurou p003-gw a ipam.mode=kubernetes (0 pools residuais) com labctl p003-gw verify e labctl k01 verify aprovados.

13.4 Negativos do Braço Cilium A, Braço Cilium B (FRR 10.7.1 + EVPN Type 5) e Síntese INV × Aberto (P004-S006 a P004-S008)

Nas sessões P004-S006, P004-S007 e P004-S008 (PASS), o estudo concluiu a comparação empírica entre Cilium A, Cilium B, OVN-Kubernetes (C/D) e INV:

- Negativos e Fronteira do Braço Cilium A (P004-S006 — V07-A, V08-A, C-neg / Gate G02):
- V07-A (C07 / H5 — Sub-redes Sobrepostas no Cilium OSS): dois namespaces compartilhando o mesmo CIDR (10.250.0.0/24 / 10.253.10.0/24) caem na mesma tabela de roteamento flat (vrf_count=0, sem isolamento L3), e dois pods solicitando o mesmo pool /32 (10.253.10.100/32) no mesmo nó falham no segundo pod com putEndpointIdInvalid "IP ipv4:10.253.10.100 is already in use" por colisão no mapa BPF global cilium_lxc.
- V08-A (C08 / H8 — Cutover de VM Legada via /32 BGP): uma VM legada QEMU/KVM (10.60.0.50/24 na leaf1, 30/30 HTTP) foi migrada por cutover para uma VMI KubeVirt anunciando 10.60.0.50/32 (CiliumPodIPPool, LPM /32 sobre /24 na border1 em 25 s, cutover_total_s=39 s, 30/30 HTTP).
- C-neg (G02): a API BGP v2 do Cilium rejeita vrf/evpn/l2vpn (strict decoding error), não instala rotas recebidas no kernel (proto bgp = 0) e não propaga a identidade eBPF (sec_id) no cabeçalho IP externo.
- Braço Cilium B — FRR 10.7.1 no Nó sob Invariante R6=0 (P004-S006 e P004-S007 — H6/G06, V09/H7, V07-B, V08-B):
- H6 (G06): o DaemonSet/frr-node (FRR 10.7.1) pareia localmente com o GoBGP do Cilium (10.255.255.1:1790) e com os switches ToR (leaf1/leaf2), mantendo r6_kernel_bgp_routes = 0 na tabela main via table-map RM-NO-KERNEL para proteger o datapath eBPF do Cilium.
- V09 (H7) e V07-B: nas VRFs Linux do nó (vrf-tenant-a VNI 10100 RT 65000:10100 e vrf-tenant-b VNI 10200 RT 65000:10200), o FRR anuncia e importa rotas EVPN Type 5 ([5]) e isola CIDRs/IPs idênticos (10.253.10.0/24, 10.253.10.100/24) com 30/30 intra-VRF, 0/10 cross-VRF e R6=0, comprovando porém que a interface primária eth0 dos pods/VMs continua presa ao mapa global cilium_lxc.
- V08-B: cutover 10.60.0.50/32 via Cilium GoBGP -> FRR 10.7.1 no nó -> border1 (AS_PATH 65203 65600 65201 65301 65311, Community 65301:100, rib_em=27 s, cutover_total=40 s, 30/30 HTTP, R6=0).
- Síntese INV × Equivalente Aberto (G07) e Higiene Final (G08) (P004-S008):
- O blueprint da Fase 2 mostra que a combinação aberta Cilium A (clusters cloud-native/L7) + OVN-Kubernetes C/D (clusters KubeVirt com same-CIDR K01, Live Migration L2 K02 e EVPN Type-2/Type-5 K03/X01/X07) atende 100% dos requisitos sem lock-in, enquanto uma PoC comercial do INV deve ser julgada pelos seis critérios objetivos INV-PoC-01 a INV-PoC-06 documentados em 20-mgc-estado-parcial.md §4.2.

Exercícios de interpretação

1. Por que a limitação “sem VRF” dos módulos Cilium OSS não descreve o braço MGC (`S002`) nem o plano OVN-Kubernetes (`S003–S004`)?
2. Por que a Live Migration preservou o IP `10.100.0.14` e a sessão TCP no OVN-Kubernetes (`K02`), mas trocou o IP do `virt-launcher` no Cilium OSS (`V05` e `V06`)?
3. Como `V04` provou com o pool de IP único `10.253.0.100/32` que `fromEndpoints` revoga o acesso no reuso de IP entre duas VMs, ao contrário de uma regra baseada apenas no endereço IP?
4. Por que o `table-map RM-NO-KERNEL` (invariante `R6=0`) é indispensável no Braço Cilium B (`H6`/`V09`), e por que mesmo com FRR `10.7.1` no nó a interface primária `eth0` do Cilium não suporta `same-CIDR` entre dois tenants (`V07-A` vs `V07-B`)?

As respostas comentadas, a matriz comparativa completa (`Cilium A` × `Cilium B` × `OVN-K C/D` × `INV`), os critérios de aceite `INV-PoC-01` a `INV-PoC-06` (`G07`) e o mapa de evidências estão em MGC, OVN-K e Cilium + KubeVirt em P004: consolidação completa de S001–S008.

Módulo 14 — Estudos Avançados P005: Conexão Dedicada eBGP □ Datapath eBPF

A trilha P005 executa os 16 estudos remanescentes (`E09–E19` e `E21–E25`) em quatro ondas paralelas sobre `vm-cilium`, combinando o Braço A (Plano de Controle eBGP / Direct Connect) com o Braço B (Datapath eBPF, Escala e Observabilidade).

14.1 Onda 1 (`P005-S001` — PASS): Idempotência BGP (`E19`), TCP MD5 + ASN 32 bits (`E09`), `netkit` vs `veth` (`E23`) e Burst IPAM (`E21`)

- Braço A — Conexão Dedicada eBGP (`19-bgp-idempotency-md5-asn32.md`):
- E19 (Idempotência 10x, Zero Resíduo e Reuso de VIP): `10` execuções consecutivas de `kubectl apply` sobre os CRDs BGP (`CiliumBGPClusterConfig`, `CiliumBGPPeerConfig`, `CiliumBGPAdvertisement` e `Service LoadBalancer svc-a` com VIP `10.202.255.190/32`) produziram `0` diferenças em `route-policies`, `advertised routes` e na RIB JSON de `border1` (`version: 488` inalterada), provando que loops GitOps não causam flaps nem BGP `UPDATE`s espúrios. A remoção limpou `100%` das rotas em `11 s` (`R6=0` rotas `proto bgp` no kernel), e o reuso imediato de `10.202.255.190/32` por `svc-b` respondeu `30/30` HTTP `200` com `0` respostas antigas.
- E09 (Sessão eBGP Autenticada TCP MD5 RFC 2385 e ASN de 32 bits `4200000001`): pareamento entre `p003-gw-worker2` (`AS 65302`) e um roteador CE FRR (`AS 4200000001`) com `authSecretRef` (`bgp-secrets-namespace=kube-system`, timers `3/9 s`, Graceful Restart). A célula positiva convergiu em `3 s` com TCP Option 19 (`md5`) provada no `tcpdump`; a senha divergente bloqueou apenas o peer inválido (`TcpExtTCPMD5Failure=2`, mantendo `3/3` sessões do fabric Clos intactas); o `Secret` ausente falhou de forma segura (`restarts=0`); e a rotação de senha em produção (`v1 -> v2`) reestabeleceu a sessão em `9,39 s` anunciando `198.18.209.0/24` com `AS_PATH` de 4 bytes (`0xfa56ea01`).
- Braço B — Datapath eBPF e Escala de Alocação (`21-netkit-vs-veth-ipam-burst.md`):
- E23 (`netkit` vs `veth` no Cilium `1.20.2` / Kernel `6.8`): provou a guarda fail-closed do `cilium-agent` ao alternar `veth -> netkit` com pods `veth` ativos no nó (`detected 1 existing endpoint(s) using incompatible datapath-modes`). Após recriação dos pods em `datapath-mode=netkit` (`mode l3`, `NOARP`, MAC `00:00:00:00:00:00`), o throughput TCP `iperf3` eliminou 100% das retransmissões TCP (`47 -> 0` same-node, `11 -> 0` cross-node) e reduziu softirqs `NET_RX` em `-8,9%` (same-node) e `-20,5%` (cross-node), preservando o bloqueio por `CiliumNetworkPolicy` (`leaked_pkts=0`).
- E21 (Escala de Burst IPAM e Warm Pool `multiPoolPreAllocation`): em rajadas de `16` pods simultâneos (`agnhost:2.47` local), `ipam.mode=kubernetes` convergiu em `5,40 s` (`2,96 pods/s`, `0` falhas); `multi-pool` frio (`multiPoolPreAllocation="default=8,e21-burst-pool=1"`) sofreu `27` falhas `postIpamFailure` (`502`) enquanto aguardava o `cilium-operator` alocar blocos no `CiliumNode`; já o `multi-pool` pré-aquecido (`multiPoolPreAllocation="default=8,e21-burst-pool=32"`) reduziu de `27` para `0` (`-100%`) as falhas de `CNI ADD` / `FailedCreatePodSandBox`. O controle negativo com pool `/29` (`6` IPs utilizáveis para `10` pods) manteve `6 Running` e `4 Pending` sem degradar outros pools.

14.2 Onda 2 (`P005-S002` — PASS): Limite de Prefixos (`E11`), Communities/Prepend/MED (`E12`), BFD < `1 s` (`E10`) e XLB L7 eBPF vs Envoy (`E22`)

- Braço A — Fronteira PE/CE na Borda eBGP (`11-bgp-maxprefix-communities-bfd.md`):

- E11 (Limite de Prefixos `maximum-prefix` e Filtro de Import `prefix-list`): o Cilium OSS `1.20.2` manteve a sessão `established` ao receber `50`, `200` e `300` prefixos de um CE FRR (`Received: 51 -> 201 -> 301` na `Adj-RIB-In` de `cilium-dbg bgp peers`, sem `max-prefix` nem filtro de import na API BGP v2) e sem instalar rotas no kernel (`kernel_proto_bgp_routes=0`, `R6=0`, route learning recusado na CFP `#34841`). No PE FRR (`border1`) configurado com `ip prefix-list E11-IMPORT-ALLOW` (`permit 198.18.0.0/16 le 32`) e `maximum-prefix 100`, os `50` prefixos declarados (`198.18.1.1/32..198.18.1.50/32`) foram aceitos, o prefixo não declarado (`198.51.100.99/32`) foi bloqueado (`% Network not in table`, `0` entradas na RIB) e o envio de `200` e `300` prefixos derrubou automaticamente a sessão com `Idle (PfxCt)` (`Maximum-prefix exceeded`).
- E12 (Communities `65400:100` / `65400:200`, `AS-path prepend` e `MED`): anunciando a mesma VIP `10.202.255.192/32` com `65400:100` em `rack1` (`p003-gw-worker`, `AS 65301`) e `65400:200` em `rack2` (`p003-gw-worker2`, `AS 65302`), ambos os next-hops (`10.255.212.1 via e12r1b` e `10.255.212.5 via e12r2b`) foram instalados em ECMP de 2 vias (`multipath`) sem `route-map` em `border1`. Ao aplicar `RM-E12-RACK1-IN`, `RM-E12-RACK2-IN` e `RM-E12-TO-CE` em `border1` (`65400:100 -> metric 10`; `65400:200 -> metric 200 + as-path prepend 2x`), `10/10` (`100%`) das requisições de `frr-e12-ce` atingiram `e12-echo-rack1` (`p003-gw-worker`, `AS 65301`). Invertendo apenas as communities nos `CiliumBGPAdvertisement`s do Kubernetes, `10/10` (`100%`) das requisições migraram em `4 s` para `e12-echo-rack2` (`p003-gw-worker2`, `AS 65302`) sem tocar na CLI do roteador de borda.
- E10 (Detecção de Falha sem e com BFD `< 1 s`): sob falha silenciosa de enlace (`iptables DROP` sem `TCP RST`/`FIN`), o Cilium com timers `3/9 s` convergiu em `8901 ms` (`> 1000 ms`) e no piso da API BGP v2 (`1/3 s`, `holdTimeSeconds=2` rejeitado pelo CRD) convergiu em `3045 ms` (`> 1000 ms`). O pareamento `FRR PE <-> FRR CE` protegido por BFD (`100 ms × 3`) detectou a falha e retirou a rota `198.18.210.0/24` em `359 ms < 1000 ms`, cumprindo `RNF05`.
- Braço B — Interposição L7 eBPF na Camada de Sockets vs Envoy L7 (`22-xlb-ebpf-socket-lb-vs-envoy.md`):
- E22 (`XLB Sockmap/sk_msg L7` vs `SocketLB L4` vs `Envoy L7`): em `100` requisições HTTP sequenciais (`keep-alive` desabilitado) em `e22-svc:8080`, a interposição `Envoy L7` (`CiliumNetworkPolicy` HTTP `e22-l7-http`, `server: envoy`) apresentou latência média de `1,014 ms` (`p95=1,418 ms`, `985,9 req/s`, `NET_RX delta=1692`); o `SocketLB L4` (`bpf-lb-sock-hostns-only=false`) reduziu a latência em `-61,3%` (`0,392 ms`, `p95=0,465 ms`, `2550,9 req/s`, `NET_RX delta=1309`); e o mecanismo XLB-style Sockmap + `sk_msg` L7 (`BPF_MAP_TYPE_SOCKHASH` + `BPF_PROG_TYPE_SOCK_OPS` + `BPF_PROG_TYPE_SK_MSG`) atingiu `0,413 ms` de latência média (`-59,3%` vs Envoy), `2418,9 req/s` (`+145,4%` vs Envoy) e o menor consumo de softirqs `NET_RX` (`1220`, `-27,9%` vs Envoy e `-6,8%` vs SocketLB L4), executando `sk_msg_redirected=160` redirecionamentos in-kernel (`bpf_msg_redirect_hash`) e bloqueando `GET /deny` diretamente em `sendmsg()` (`SK_DROP`, `curl_rc=55`), além dos controles negativos `403` em `GET /deny` (Envoy L7), `rc=28` (tenant não autorizado) e `rc=7` (`0` réplicas).

14.3 Onda 3 (`P005-S003` — PASS): Redundância Dual-Border e Graceful Restart (`E13`), eBGP IPv6 Nativo (`E14`) e Observabilidade BGP + Hubble (`E17` + `E25`)

- Braço A — Alta Disponibilidade Dual-Border, Graceful Restart e eBGP IPv6 Nativo (`13-bgp-dual-border-gr-ipv6.md`):
- E13 (Redundância Dual-Border ECMP, Failover Controlado e Restart do `cilium-agent` com/sem GR): com `p003-gw-worker` (`AS 65301`) pareado a `border1` (`AS 65400`) e `p003-gw-worker2` (`AS 65302`) pareado a `frr-e13-border2` (`AS 65401`) anunciando a VIP `10.202.255.193/32` para `frr-e13-client` (`AS 65513`), o cliente balanceou o tráfego em ECMP (`rack1=12/30`, `rack2=18/30`), convergiu imediatamente para `border2` (`rack2=20/20`) durante `neighbor 10.255.213.10 shutdown` com `0` falhas (`71/71` HTTP `200`, `max_gap_ms=115 ms`) e restaurou o ECMP (`rack1=13/30`, `rack2=17/30`) após `no shutdown`. Em caminho único (`p003-gw-worker2 <-> frr-e13-border2`), o restart forçado do `cilium-agent` com `gracefulRestart.enabled: true` (`restartTimeSeconds: 30` + `bgp graceful-restart preserve-fw-state`) preservou a rota `(stale)` na FIB e os mapas eBPF no kernel com `139/139` respostas HTTP `200` (`0` perdas, `max_gap_ms=117 ms`), ao passo que o controle negativo sem GR (`enabled: false`) expurgou imediatamente a rota e provocou `78` falhas (`max_gap_ms=8879 ms`).
- E14 (Sessão eBGP IPv6 Dedicada `fd00:10:255:214::/64` e VIP `fd14::a/128` Fim a Fim): resolveu experimentalmente a limitação de `P002-S001`: na Célula 1, anunciar `ipv6/unicast` sobre sessão TCP IPv4 (`10.255.214.1 <-> 10.255.214.2`) gera next-hop IPv4-mapped `::ffff:10.255.214.1` (`::ffff:aff:d601`) incompatível com encaminhamento IPv6 nativo; na Célula 2, com sessão TCP/179 puramente IPv6 (`fd00:10:255:214::1 <-> fd00:10:255:214::2`), `border1` e `frr-e14-client` (`fd00:198:19::10`) instalaram `fd14::a/128` com next-hop IPv6 nativo e serviram `30/30` requisições HTTP IPv6 (`http://[fd14::a]:8080/hostname`), com withdraw negativo em `2 s` (`5/5` bloqueados) e restauração (`5/5` HTTP `200`).
- Braço B — Observabilidade Contínua BGP (`ACTIVE`/`DOWN`/`UNKNOWN`) e Microsserviços com Hubble (`17-bgp-hubble-observability.md`):
- E17 (Máquina de Estados BGP por 3 Leituras Consecutivas e Fronteira de Visibilidade): amostrando `:9962/metrics` e `cilium-dbg bgp peers` a cada `3 s`, um flap curto de `2` leituras `0` (`max_down_streak=2/3`) foi amortecido mantendo `derived=ACTIVE` (`false_down=0`); um flap sustentado (`>= 3` leituras `0`) transicionou `ACTIVE -> DOWN` em `7596 ms` e

retornou `DOWN -> ACTIVE` em `11166 ms` após `3` leituras `1` consecutivas; `3/3` falhas de scrape (`:19962`) transicionaram deterministicamente para `UNKNOWN`; e a inspeção da RIB de `border1` comprovou que o `AS_PATH` completo (`65203 65600 65201 65301`) e as communities (`65301:100`) só são visíveis no roteador de borda.

- E25 (Visibilidade Hubble `L3/L4`, `L7 HTTP/DNS`, `TLS :8443` e Prometheus `:9965`): no cluster `p003-gw`, o Hubble registrou `hubble_forwarded=302`, `hubble_dropped_policy=10` (`Policy denied`) e `hubble_from_ip_198_19=120` fluxos norte-sul preservando o IP externo `198.19.0.10` (`externalTrafficPolicy: Local`); no proxy Envoy L7, capturou `hubble_l7_200=10` (`GET /hostname`), `hubble_l7_403=5` (`DROPPED` em `GET /denied`) e `hubble_l7_dns=20`; em TLS `:8443`, capturou `hubble_8443_l4_flows=92` com identidade Cilium visível e `0` vazamentos de URL L7 (`hubble_8443_l7_cleartext_leak=0`); e correlacionou as métricas Prometheus (`hubble_flows_processed_total=2836`, `hubble_drop_total=65`, `hubble_http_requests_total=15`, `hubble_dns_queries_total=8`) com a continuidade do ring buffer local (`Ok (3,015/4,095 flows)`) durante indisponibilidade do Relay (`:4245`).

14.4 Onda 4 (`P005-S004` — PASS): VRF por Tenant via Community (`E15`), 3 Modos de Retorno & Egress Gateway (`E16`), MTU 9000/QinQ/MACsec vs WireGuard (`E18`) e DRA no Cilium (`E24`)

- Braço A — VRF por Tenant, Terminação PE/CE & Retorno, e Camada de Enlace L2 (`15-bgp-vrf-return-paths-l2-mtu-qinq-macsec.md`):
- E15 (Isolamento de VRF por Tenant no Border via BGP Community): como o Cilium OSS não possui VRF na BGP Control Plane, `p003-gw-worker` (`AS 65301`) anunciou numa única sessão eBGP (`10.255.215.1 <-> 10.255.215.2`) três VIPs tagueadas com communities distintas: `10.202.255.195/32` (`65400:1010`), `10.202.255.196/32` (`65400:1020`) e `10.202.255.199/32` (`65400:9999`). No PE `frr-e15-pe` (`AS 65400`), `route-map RM-E15-IMPORT-A/B` + `import vrf default` importaram seletivamente `10.202.255.195/32` exclusivamente em `vrf-e15-a` (`table 1510`) e `10.202.255.196/32` exclusivamente em `vrf-e15-b` (`table 1520`), servindo `30/30` HTTP `200` intra-tenant (`e15-echo-a` e `e15-echo-b`) e bloqueando `0/5` em todas as tentativas cross-tenant (`Client A -> VIP B`, `Client B -> VIP A`, `Client A -> Client B` e community não autorizada `65400:9999`), com `R6=0`.
- E16 (Desenho de Terminação PE/CE, 3 Modos de Retorno e `CiliumEgressGatewayPolicy`): avaliou os três desenhos de retorno para prefixos externos anunciados pelo cliente:
- Modo 1 (Rota estática no nó, `R6=0`): sem rota de retorno no kernel Linux para `198.19.16.0/24`, o tráfego falha com `0/3` HTTP mesmo quando o GoBGP do Cilium mostra `Received: 2`; adicionando `ip route replace 198.19.16.0/24 via 10.255.216.2 dev eth16`, o serviço responde `30/30` HTTP `200` mantendo `R6=0`.
- Modo 2 (FRR co-implantado no nó com `prefix-list`): sem rota para `198.19.116.0/24`, `0/3` HTTP; com daemon FRR auxiliar no nó (`frr-e16-node`, `AS 65316`, `10.255.216.3`) importando `198.19.116.0/24` via `E16-CUST-ONLY (RM-E16-IN)`, a rota `proto bgp` é instalada no kernel servindo `30/30` HTTP `200` e restaurando `R6=0` após encerramento do speaker auxiliar.
- Modo 3 (Outbound determinístico com `CiliumEgressGatewayPolicy`): o pod selecionado (`e16-egress-client`, `egress-authorized=true`) saiu pelo nó gateway (`p003-gw-worker`) com SNAT determinístico `10.255.216.10` (`30/30` HTTP `200`, `client_ip=10.255.216.10`), enquanto o pod não selecionado (`e16-unmatched-client`) saiu com o IP primário `10.255.216.1` e foi bloqueado (`0/5`) pela ACL de borda do PE.
- E18 (MTU 9000 Jumbo Frames, QinQ `802.1ad` e MACsec `802.1AE` vs Cilium WireGuard):
- Célula 1 (MTU 9000 & PMTU): `30/30` pings `DF=1` de `8972 B` payload (`9000 B` IPv4 / `9014 B` Ethernet, RTT `0,065 ms`) sobre `mtu 9000` fim a fim vs controle negativo com `e18pe0 mtu 1500` (`0/5` pings `DF=1` e captura `ICMP 10.202.255.198 unreachable - need to frag (mtu 1500)`).
- Célula 2 (QinQ IEEE 802.1ad): sessão eBGP `Established` e `10/10` pings sobre `S-TAG 100` (`0x88a8`) + `C-TAG 200` (`0x8100`) comprovados via `tcpdump -e` vs controle negativo com `C-TAG 201` divergente (`0/5`).
- Célula 3 (MACsec IEEE 802.1AE `gcm-aes-128` vs Cilium WireGuard): sessão eBGP `Established` e `10/10` pings sobre `macsec0` (`encrypt on`), com `100%` dos quadros na interface base encapsulados em `ethertype MACsec (0x88e5)` (`OutPktsEncrypted=40`, `InPktsOK=43`, `0` pacotes TCP/179 ou ICMP em claro) vs controle negativo com SAK divergente em `TX SA 1` (`0/5` pings e `InPktsNotValid=15`).
- Braço B — Dynamic Resource Allocation (`resource.k8s.io/v1`) no Cilium (`24-cilium-dra-network-device.md`):
- E24 (DRA `resource.k8s.io/v1` `NetworkDeviceData`, Coexistência `eth0` + `net1`/`net2` e Ciclo de Vida): provou que o chart estável `cilium-1.20.2.tgz` não embute driver DRA (`0` chaves DRA; branch `feature/dra-driver` `157b5331c727` é experimental), enquanto o Kubernetes `v1.35.0` oferece nativamente `resource.k8s.io/v1` GA (`DeviceClass`, `ResourceClaim`, `ResourceClaimTemplate`, `ResourceSlice`). Publicando o `ResourceSlice` `p003-gw-worker2-cilium-netpool-slice-0` (`driver: network.cilium.io`, `cilium-netdev-0` `net1/mtu=1500` e `cilium-netdev-1` `net2/mtu=9000`), o `kube-scheduler` alocou automaticamente os claims com

seletores CEL (`device.attributes["network.cilium.io"].ebpfAttach == true`), o reconciliador `NodePrepareResources` (`reconcile_dra_prepare` / `reconcile_dra_unprepare`) executou `3x` de forma idempotente (`ipv4_addrs=1` sem IPs duplicados), preencheu `status.devices[0].networkData` (`ips`, `hardwareAddress`, `interfaceName`) e manteve `10/10` HTTP `200` no datapath DRA secundário (`10.254.24.10 -> 10.254.24.11` sobre `br-cilium-dra`) em coexistência com o datapath eBPF primário (`eth0` `10/10` allow, `5/5` deny por `CiliumNetworkPolicy/e24-deny-untrusted` e `10/10` HTTP `200` via BGP VIP `10.202.255.24/32` a partir de `clab-p003-gw-fabric-client`). Nos controles negativos, CEL inválido foi rejeitado na admissão (`undeclared reference to 'nonExistentFunc'`), `rdma == true` e o 3º claim (`e24-net-claim-c-exhausted`) contra pool de 2 dispositivos ficaram `Pending`, a exclusão prematura do claim ativo foi bloqueada pelo finalizer `resource.kubernetes.io/delete-protection`, e o teardown do Pod A executou `Unprepare` limpo (`net1_orfao_em_app_a=0`) realocando imediatamente `cilium-netdev-0` para o 3º claim.

Exercícios de interpretação do Módulo 14

1. Por que no estudo `E11` o Cilium OSS mantém a sessão BGP `established` ao receber `300` prefixos e continua com `0` rotas `proto bgp` no kernel (`R6=0`), e por que o `maximum-prefix` e o `prefix-list` de import precisam residir no roteador de borda FRR/SR Linux?
2. Como o estudo `E13` comprova que `gracefulRestart.enabled: true` no Cilium evita perda de pacotes durante o restart do `cilium-agent` (`139/139` HTTP `200`, `0` falhas vs `78` falhas sem GR), e qual papel os mapas eBPF no kernel Linux desempenham enquanto o agente reinicia?
3. No estudo `E16`, por que a presença de uma rota na `Adj-RIB-In` do GoBGP do Cilium (`Received > 0`) não permite que o pod responda ao cliente sem uma rota de retorno na FIB do kernel Linux, e quando escolher entre Rota Estática (Modo 1), FRR no Nó (Modo 2) ou `CiliumEgressGatewayPolicy` (Modo 3)?
4. Qual é a diferença de camada e escopo entre MACsec (`802.1AE`, `0x88e5`) e Cilium WireGuard (`51820/UDP`) demonstrada em `E18`, e por que o MACsec cifra inclusive a sessão TCP/179 do eBGP entre nó e ToR/PE?
5. Como o estudo `E24` (`resource.k8s.io/v1` DRA) preserva a governança do Cilium na interface primária `eth0` (`CiliumNetworkPolicy` + BGP VIP) enquanto anexa interfaces secundárias dedicadas (`net1`/`net2`) publicadas em `status.devices[].networkData`?

15. Módulo 15 — Trilha P006: Datapath Avançado (E26–E29), Multi-Cluster & SRv6 (E30–E33) e Saneamento Integral (C1–C4)

15.1 Onda 1 (`P006-S001` — PASS): LoadBalancer TCX/XDP + DSR & Maglev (`E26`), Cilium Cluster Mesh / MCS-API sobre BGP (`E30`) e Saneamento `Bloco C1`

- Braço A — LoadBalancer TCX/XDP, Anúncio BGP Seletivo (`ETP=Local` vs `ETP=Cluster`) e Maglev Consistent Hashing (`26-lb-xdp-dsr-maglev-clustermesh.md`):
- E26 (`TCX` + `loadBalancer.algorithm=maglev` `M=16381`): comparou três VIPs BGP (`10.202.255.26/32` `ETP=Cluster` 1 backend em `worker2`, `10.202.255.27/32` `ETP=Cluster` 3 backends e `10.202.255.28/32` `ETP=Local` 1 backend em `worker2`). Na RIB de `border1`, `.26` e `.27` foram anunciadas em ECMP por ambos os workers (`AS 65301` e `AS 65302`), enquanto `.28` (`ETP=Local`) foi anunciada exclusivamente por `p003-gw-worker2` (`AS 65302`), eliminando o salto intermediário e preservando `100%` (`10/10`) do IP real do cliente externo (`198.19.0.10`) nos traces do `cilium-dbg monitor`, contra o SNAT de nó (`172.19.0.5`/`172.19.0.6`) observado em `.26`. No anel primo Maglev (`Table Size: 16381`) (`[146..148]/v4`), a remoção do 3º backend (`186`) realocou apenas os slots que lhe pertenciam, mantendo `0` diffs (`0` rehash colateral) nos slots dos backends sobreviventes (`185` e `187`) e servindo `20/20` HTTP `200`.
- Braço B — Cilium Cluster Mesh / MCS-API (`EndpointSlice` Multi-Cluster) e Failover Global sobre BGP (`26-lb-xdp-dsr-maglev-clustermesh.md`):
- E30 (Reconciliação Multi-Cluster `EndpointSlice`, Failover Global e Controles `3A`/`3B`): verificou a separação de identidades de cluster (`k01` `cluster_id=1` vs `p003-gw` `cluster_id=2`, `max_connected_clusters=255`) e reconciliou o `Service` global `e30-global-svc` (`10.202.255.30/32`, `service.cilium.io/global: "true"`) mesclando a `EndpointSlice` local (`e30-global-svc-rtdbn` `10.245.2.19:8080`) com a `EndpointSlice` remota (`e30-global-svc-remote-c2` `10.245.1.180:8080`, `managed-by: cilium-clustermesh-mcs`) nos mapas eBPF de LB (`ID 166` `ClusterIP` e `ID 167` `LoadBalancer`). Com ambos os clusters ativos, o serviço respondeu `20/20` E-W (`15` local / `5` remoto) e `20/20` N-S via BGP (`10` local / `10` remoto); ao escalar o deployment local para `0`, ocorreu failover global automático sem perda (`20/20` E-W e `20/20` N-S servidos por `remote-c2`). Nos controles negativos, a `CiliumNetworkPolicy` `e30-deny-remote-cluster` (`egressDeny` para `cluster-origin: remote-c2`) bloqueou `5/5` conexões (`3A`, com restauração `5/5` após remoção), e o unexport da `EndpointSlice` remota com `local=0` removeu todos os backends ativos do mapa BPF (`3B`, `5/5` recusados).

- Braço C — Saneamento Crítico `Bloco C1` (`revisao-projeto-2026-09-26.md`):
- Resolvidos os 8 itens críticos (`A4–A8`, `A10–A12`): sintaxe bash corrigida em `s012/11` e `s012/81` (`bash -n 0` erros), `studies/p003/e08-lifecycle-synthesis.md` unificada com a versão pública sanitizada (`diff=0`), chaves privadas estáticas removidas de `s009/10-tls.yaml` com gerador idempotente `s009/gen-tls.sh`, `DATABASE_PASSWORD` lida de `local.conf` em `s011/reconf-ovs.sh`, e correções funcionais em `s004-record-ports.sh` (`A10`), `s013/02-c01-c03.sh` (`A11`) e `s010-run.sh` (`A12`).

Apêndice do instrutor

O laboratório já deve estar rodando. A reconstrução é referência, não exercício, e só acontece em ambiente vazio confirmado.

Rebuild do `k01` em dois terminais

```
sudo apt-get update && sudo apt-get install -y git ca-certificates
sudo git clone https://github.com/reinaldosaraiva/learn-cilium.git /opt/learn-cilium
sudo ln -s /opt/learn-cilium/poc-k8s-fabric /opt/poc-k8s-fabric
export LAB_DIR=/opt/poc-k8s-fabric && cd "$LAB_DIR"
sudo ./scripts/00-prep-vm.sh
sudo sysctl -w net.ipv4.ip_forward=1
sudo docker ps -a --format 'table {{.Names}}\t{{.Status}}'; sudo kind get clusters
```

Se houver containers `clab-poc-k8s-kind-*` ou o cluster `k01`, pare. No Terminal 1:

```
sudo TOPO=topo/poc-kind.clab.yml ./scripts/01-deploy-fabric.sh
```

No Terminal 2, assim que a API do kind existir:

```
sudo kind export kubeconfig --name k01 --kubeconfig /root/.kube/k01-rebuild.config
sudo KUBECONFIG=/root/.kube/k01-rebuild.config \
  VALUES=k8s/cilium/values-dualstack.yaml ./scripts/02-install-cilium.sh
k01() { sudo kubectl --kubeconfig /root/.kube/k01-rebuild.config --context kind-k01 "$@"; }
DEVICES=$(k01 -n kube-system get cm cilium-config -o jsonpath='{.data.devices}')
if [ "$DEVICES" != "eth+" ]; then
  k01 -n kube-system patch cm cilium-config --type merge \
    -p '{"data":{"devices":"eth+"}}'
  k01 -n kube-system rollout restart ds/cilium
  k01 -n kube-system rollout status ds/cilium --timeout=5m
fi
sudo -E KUBECONFIG=/root/.kube/k01-rebuild.config \
  RACK1_NODES="k01-control-plane k01-worker" RACK2_NODES="k01-worker2" \
  ./scripts/03-apply-bgp.sh
sudo docker exec clab-poc-k8s-kind-client-ext ip -4 addr show dev eth1 \
  | grep -q 203.0.113.10 || echo "GATE L1: restaurar IPv4 do client-ext"
sudo ./scripts/06-expor-vip-na-vpc.sh && curl -fsS --max-time 5 http://10.201.255.10/hostname
```

Não execute o toggle de guard que o script imprime para usar o túnel SSH local.

Sandbox `p003-gw`

Os artefatos ficam em `studies/p003/`: topologia (`topo/`), configs SR Linux (`configs/srl/`), values e chart fixado (`base/values-p003.yaml`, `base/cilium-1.20.2.tgz`), BGP (`base/bgp/`), Gateway e rotas (`base/gateway.yaml`), fixtures (`fixtures/`) e os casos por sessão (`cases/`). O diff em relação ao kit está em `studies/p003/diff-vs-kit.md`. O deploy do containerlab deve rodar com `nohup` e log, nunca em foreground com timeout de canal SSH: uma interrupção deixa os SR Linux sem startup-config.

Antes de cada sessão, rode o canário do `k01` (`studies/p003/cases/k01-canary.sh`): 10/10 HTTP 200 na VIP e UID inalterado. Ao terminar, restaure o baseline (`helm upgrade` de volta ao perfil W0 native, IPAM `kubernetes`, sem pools) e remova objetos de teste por nome exato.

Lições operacionais

#	Lição	Gate
L1	`client-ext` pode perder o IPv4 após deploy	validar `203.0.113.10` sempre
L2	`docker stop` de SR Linux destrói os veths	falhas só com `admin-state disable` via `sr_cli`
L3	`clab destroy` parcial apaga o kind	nunca destroy/redeploy com cluster no ar
L4	contagem de falhas superestima blackhole	medir por gap entre OKs
L5	bulk-delete por label leva colaterais	deletar por lista explícita de nomes
L6	`helm upgrade` regenera o ConfigMap	reconferir `devices=eth+`
L7	testbed OpenStack tem cap de 8 GiB	gate de memória antes de cada spawn de VM
L8	`journald` dentro dos nós kind acumula `Shmem` em `/run/log/journal`	rodar `journalctl --vacuum-size=10M` nos containers kind para preservar `MemAvailable >= 4,00 GiB` (`R3`)

Limites do que foi demonstrado

- O fabric roda em containers com simulação userspace; use relações, nunca valores absolutos de throughput ou latência.
- A VIP IPv6 e o pod→pod IPv6 cross-node ficaram limitados pela topologia IPv4 do underlay externo.
- ExternalAuth é experimental na 1.20.2 e tem os defeitos listados no Módulo 7; a fixture não é um IdP.
- Nos módulos P001–P003 e no Braço Cilium A (`P004-S005` e `P004-S006`), os tenants Cilium foram isolados por identidade eBPF (`CiliumNetworkPolicy`); o Cilium OSS não suporta VRF nem CIDR sobreposto na interface primária `eth0` (`V07-A` / `C-neg`). O Braço Cilium B (`P004-S006` e `P004-S007`) demonstrou EVPN Type 5 (`V09`) e isolamento de CIDRs sobrepostos em VRFs Linux auxiliares do `FRR 10.7.1` no nó (`V07-B`, mantendo `0` rotas BGP na tabela `main` via `R6`), enquanto o braço MGC (`P004-S002`) e o braço OVN-Kubernetes + EVPN (`P004-S003` e `P004-S004`) provaram nativamente o isolamento de CIDRs sobrepostos na interface primária (`UserDefinedNetwork` `10.100.0.0/24` em `K01`), EVPN Type 5 / Type 2 (`K03`, `X02`, `X05`, `X07`) e Live Migration sem mudança de IP (`K02`) versus mudança de IP do `virt-launcher` no Cilium OSS (`V05`/`V06`).
- A sincronização entre identidade Kubernetes e Security Group Neutron não foi implementada; a conclusão da trilha híbrida é "seguro sob sequenciamento manual".
- Nas 4 Ondas de `P005` (`P005-S001` a `P005-S004` — `16/16` estudos concluídos com `PASS`), foram provados: idempotência declarativa `10x` e reuso de VIP BGP sem resíduo (`E19`), autenticação TCP MD5 (`RFC 2385`, `authSecretRef`) com ASN de 32 bits (`4200000001`) e rotação de chave em produção (`E09`), substituição de `veth` por `netkit` (`mode l3`, `NOARP`) no datapath eBPF (`E23`), eliminação de `postIpamFailure` em rajadas de pods (`agnhost:2.47`) com `ipam.multiPoolPreAllocation` (`E21`), limite de prefixos `maximum-prefix 100` e filtro de import na borda FRR vs ausência de import no Cilium (`E11`), marcação de BGP communities no Cilium acionando `MED` e `AS-path prepend` na borda (`E12`), detecção de falha sub-segundo com BFD (`359 ms < 1 s`) na borda FRR vs piso de `3045 ms` nos timers `1/3 s` do Cilium (`E10`), aceleração L7 in-kernel via `sockmap`/`bpf_sock_ops`/`sk_msg` (`XLB`) vs `Envoy L7` (`E22`), redundância dual-border ECMP e restart do `cilium-agent` sem perda com Graceful Restart (`139/139` c/ GR vs `8879 ms` s/ GR, `E13`), sessão eBGP IPv6 dedicada servindo a VIP `fd14::a/128` fim a fim (`30/30` HTTP `200`, `E14`), observabilidade contínua BGP por 3 leituras consecutivas (`ACTIVE`/`DOWN`/`UNKNOWN`, `E17`) combinada com fluxos Hubble `L3/L4`, `L7 HTTP/DNS`, `TLS :8443` e métricas Prometheus (`E25`), isolamento de VRF por tenant no border via BGP community (`65400:1010` vs `65400:1020`, `E15`), os 3 modos de retorno PE/CE (`Rota Estática`, `FRR no Nó` e `CiliumEgressGatewayPolicy`, `E16`), a fronteira física/enlace de `MTU 9000` Jumbo Frames, `QinQ 802.1ad` e `MACsec 802.1AE` vs `WireGuard` (`E18`), e a alocação dinâmica de dispositivos de rede via DRA `resource.k8s.io/v1` (`NetworkDeviceData`, `E24`).
- Nós reais na nuvem provaram overlay e BGP; native routing e VIP anycast dependem da postura de spoofing da porta.

Próximos estudos

A trilha completa de `P005` (`E09–E19` e `E21–E25`, somando `25/25` estudos totais do repositório entre `E01` e `E25`) encontra-se integralmente concluída com `PASS` (`v2.4.0`) e consolidada em `docs/proximos-estudos.md` e nos oito dossiês públicos de `P005` listados abaixo.

Referências públicas

- Resultados resumidos do laboratório
- MGC, OVN-K e Cilium + KubeVirt em P004: consolidação completa de S001–S008
- P005 Onda 1 — Braço A (`E19` + `E09`): Idempotência BGP e TCP MD5 com ASN 32 bits
- P005 Onda 1 — Braço B (`E23` + `E21`): `netkit` vs `veth` e Burst IPAM com Warm Pool
- P005 Onda 2 — Braço A (`E11` + `E12` + `E10`): Limite de Prefixos, Communities/Prepend/MED e BFD `< 1 s`
- P005 Onda 2 — Braço B (`E22`): XLB Balanceamento L7 eBPF (`sockmap`/`sk_msg`) vs `SocketLB L4` e `Envoy L7`
- P005 Onda 3 — Braço A (`E13` + `E14`): Redundância Dual-Border, Failover com/sem Graceful Restart e eBGP IPv6 Nativo (`fd14::a/128`)
- P005 Onda 3 — Braço B (`E17` + `E25`): Observabilidade Contínua BGP (`ACTIVE`/`DOWN`/`UNKNOWN`) e Microsserviços com Hubble
- P005 Onda 4 — Braço A (`E15` + `E16` + `E18`): VRF por Tenant via Community, 3 Modos de Retorno PE/CE & Egress Gateway e Enlace L2 (MTU 9000, QinQ `802.1ad` e MACsec `802.1AE` vs WireGuard)
- P005 Onda 4 — Braço B (`E24`): Dynamic Resource Allocation (DRA `resource.k8s.io/v1`) para Dispositivos de Rede no Cilium (`NetworkDeviceData`)
- Índice dos estudos P003, P004 e P005, síntese E08 e caso C5
- Cilium BGP Control Plane
- Recursos do BGP Control Plane
- Gateway API no Cilium
- Multi-Pool IPAM
- WireGuard no Cilium
- Políticas Kubernetes do Cilium
- Neutron: roteamento dinâmico BGP